ETL

Pertemuan 5 - Teknologi Perekayasaan Data

Politeknik Statistika STIS

Siti Mariyah, Ph.D

Agenda Pertemuan

1. Apa itu ETL?
2. ETL Tools
3. Pengenalan SQL Server Integration Services
4. Implementasi

ETL

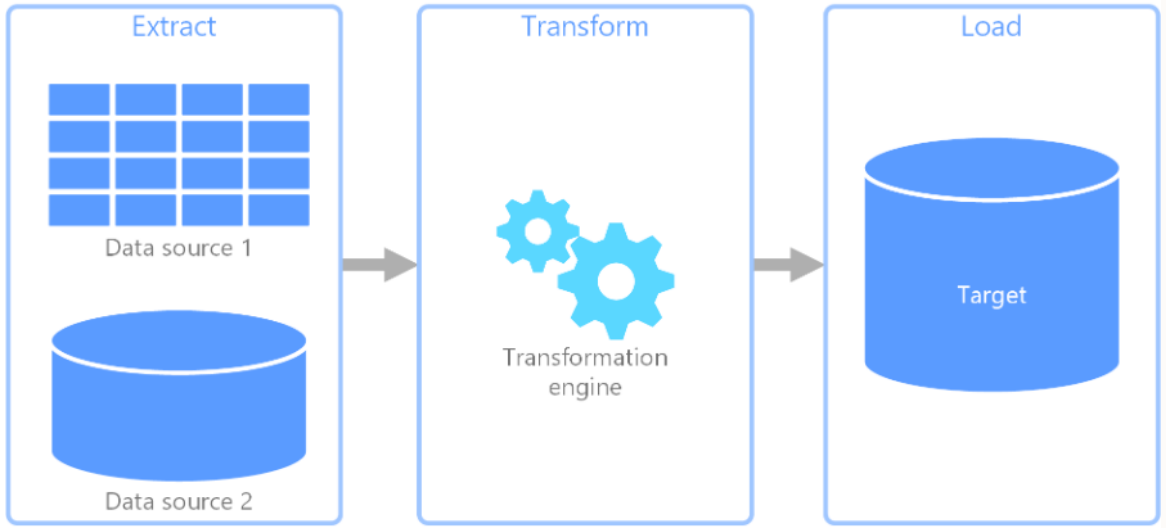

- **ETL** merupakan singkatan dari Extract, Transform, Load
- **Extract, transform, and load (ETL)** merupakan *data pipeline* yang digunakan untuk mengumpulkan data dari berbagai sumber. Kemudian data tersebut ditransformasi berdasarkan *rule* bisnis dan di-*load* ke target repositori.
- **Tranformasi** dapat melibatkan berbagai operasi, seperti *filtering, sorting, aggregating, joining data, cleaning data, deduplicating, dan validating data*.
- **Proses ETL** dapat berlangsung secara paralel, dimana proses transformasi dan load data dilakukan untuk sebagian data yang telah berhasil di ekstrak.

ELT

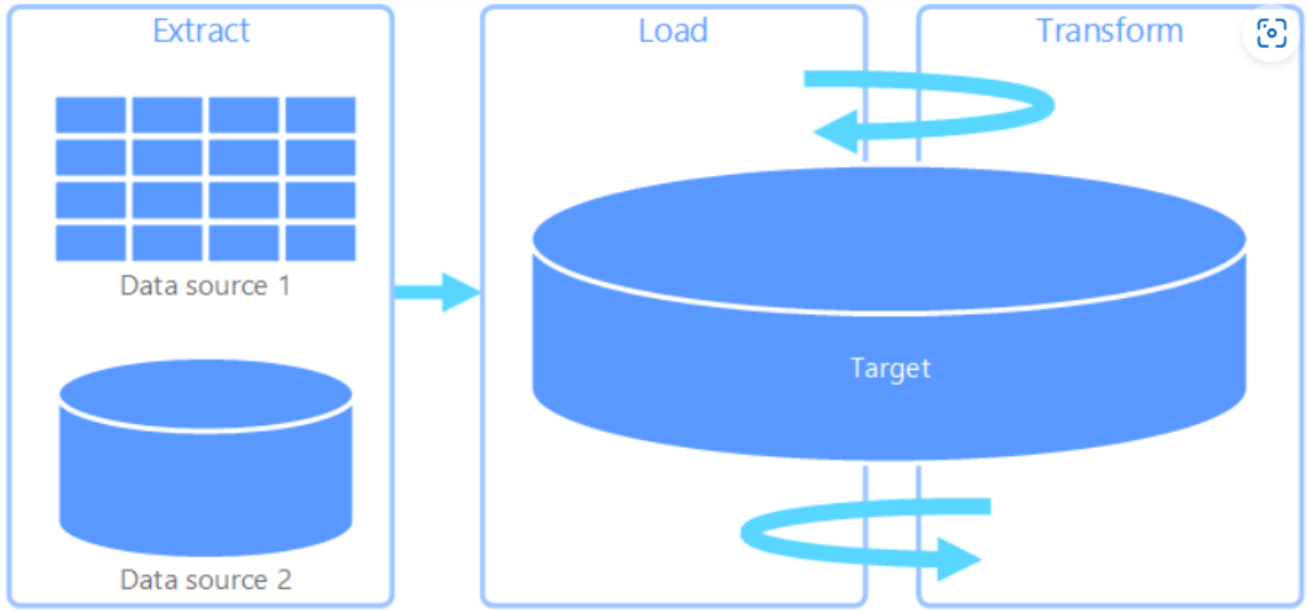

- Berbeda dengan **ETL**, transformasi pada proses **ELT** berlangsung pada repositori target.
- ELT dilakukan dengan mempertimbangkan **spesifikasi dari sistem target** untuk mengakomodir penyimpanan dan pemrosesan data.
- Biasanya, ELT dilakukan pada **sistem *Big Data***, dimana data yang berasal dari berbagai sumber di-*load* terlebih dahulu ke penyimpanan, seperti HDFS, untuk kemudian ditransformasi sesuai dengan kebutuhan analisis.

Data Extraction

- Proses *data extraction* dapat melibatkan beberapa sumber data dengan format yang berbeda
- Beberapa hal yang perlu diperhatikan saat *data extraction* yaitu:
  a. Koneksi ke sumber data: ole db, odbc, file connector, flat file, excel, dll
  b. Struktur data dari sumber data: nama kolom, tipe kolom, *length*
  c. Untuk data tipe flat file, perlu ditentukan *delimiter, text qualifier*, serta *column header*
  d. Penentuan kolom apa saja yang akan di-*load*

Data Transformation

Data Hasil Ekstraksi

SubCategoryCode	CategoryCode	SubCategoryName
50	A	Bahan Pokok
51	A	Cokelat & Permen
52	A	Makanan & Minuman Lainnya
53	A	Makanan Beku
54	A	Makanan Instan
55	A	Makanan Kaleng
56	A	Makanan Ringan
57	A	Makanan Segar
58	A	Makanan Siap Saji
59	A	Menu Sarapan
60	A	Minuman
61	A	Roti & Kue
62	A	Susu & Olahan
63	B	Kabel & Sparepart
64	B	Kamera Pengintai
65	B	Kelistrikan
66	B	Media Player
67	B	Pencahayaan
68	B	Pendingin
69	B	Penyedot Debu
70	B	Perangkat Dapur

✓ Filtering

SubCategoryCode	CategoryCode	SubCategoryName
50	A	Bahan Pokok
51	A	Cokelat & Permen
52	A	Makanan & Minuman Lainnya
53	A	Makanan Beku
54	A	Makanan Instan
55	A	Makanan Kaleng
56	A	Makanan Ringan
57	A	Makanan Segar
58	A	Makanan Siap Saji
59	A	Menu Sarapan
60	A	Minuman
61	A	Roti & Kue
62	A	Susu & Olahan

✓ Sorting

SubCategoryCode	CategoryCode	SubCategoryName
62	A	Susu & Olahan
61	A	Roti & Kue
60	A	Minuman
59	A	Menu Sarapan
58	A	Makanan Siap Saji
57	A	Makanan Segar
56	A	Makanan Ringan
55	A	Makanan Kaleng
54	A	Makanan Instan
53	A	Makanan Beku
52	A	Makanan & Minuman Lainnya
51	A	Cokelat & Permen
50	A	Bahan Pokok

✓ Joining Data

SubCategoryCode	CategoryCode	CategoryName	SubCategoryName
62	A	Makanan & Minuman	Susu & Olahan
61	A	Makanan & Minuman	Roti & Kue
60	A	Makanan & Minuman	Minuman
59	A	Makanan & Minuman	Menu Sarapan
58	A	Makanan & Minuman	Makanan Siap Saji
57	A	Makanan & Minuman	Makanan Segar
56	A	Makanan & Minuman	Makanan Ringan
55	A	Makanan & Minuman	Makanan Kaleng
54	A	Makanan & Minuman	Makanan Instan
53	A	Makanan & Minuman	Makanan Beku
52	A	Makanan & Minuman	Makanan & Minuman Lainnya
51	A	Makanan & Minuman	Cokelat & Permen
50	A	Makanan & Minuman	Bahan Pokok

✓ Aggregating

CategoryCode	CategoryName	cnt
A	Makanan & Minuman	13

Data Transformation

Data Hasil Ekstraksi

email	Name
rharrowing0@sciencedaily.com	Reidar Harrowing
mjobes1@nasa.gov	Marcellus Jobes
rdymott2@amazon.co.uk	Reynold Dymott
ssaphir3@cdc.gov	Suzette Saphir
kmccard4@dailymail.co.uk	Kinny McCard
rstiggers5@hp.com	Rance Stiggers
raitchinson6@angelfire.com	Rustie Aitchinson
hprandin7@paypal.com	Heidie Prandin
nbrownsmith8@odnoklassniki.ru	Nikolas Brownsmith
mbolger9@networkadvertising.org	Merry Bolger
nnyssena@jigsy.com	Neila Nyssen
afoaleb@lulu.com	Annabelle Foale
hstanettc@walmart.com	Hayward Stanett
ayablsleyd@pinterest.com	Ardine Yablsley
jrothe@fotki.com	Josephina Roth
icastagnetf@cnet.com	Ignacio Castagnet
gsiburng@zdnet.com	Germain Siburn
csmithenh@google.it	Chere Smithen
tbeeckeri@slashdot.org	Theressa Beecker
tfotittj@google.com.au	Theodosia Fotitt
bprovestk@weibo.com	Brook Provest
kdummerl@opera.com	Kelsey Dummer

✓ **Cleaning Data**

	id	FirstName	LastName	EmailAddress
1	1	Reidar	Harrowing	rharrowing0@sciencedaily.com
2	2	Marcellus	Jobes	mjobes1@nasa.gov
3	3	Reynold	Dymott	rdymott2@amazon.co.uk
4	4	Suzette	Saphir	ssaphir3@cdc.gov
5	5	Kinny	McCard	kmccard4@dailymail.co.uk

✓ **Deduplicating**

Mendeteksi jika terdapat duplikasi record

✓ **Validating Data**

Memvalidasi isian data, seperti:

a. Terdapat email yang tidak sesuai format
b. Nama yang null
c. Panjang karakter kolom nama dan email

Data Loading

- Proses *data loading* dapat menghasilkan output dengan format data sesuai dengan kebutuhan
- Beberapa hal yang perlu diperhatikan saat *data loading* yaitu:
  a. Koneksi ke repositori target: ole db, odbc, file connector, flat file, excel, dll
  b. Struktur data pada repositori target: nama kolom, tipe kolom, *length*
  c. Untuk data tipe flat file, perlu ditentukan *delimiter, text qualifier*, serta *column header*
  d. Mapping kolom pada sumber data dengan kolom pada skema target

email	Name
rharrowing0@sciencedaily.com	Reidar Harrowing
mjobes1@nasa.gov	Marcellus Jobes
rdymott2@amazon.co.uk	Reynold Dymott
ssaphir3@cdc.gov	Suzette Saphir
kmccard4@dailymail.co.uk	Kinny McCard
rstiggers5@hp.com	Rance Stiggers
raitchinson6@angelfire.com	Rustie Aitchinson
hprandin7@paypal.com	Heidie Prandin

	id	FirstName	LastName	EmailAddress
1	1	Reidar	Harrowing	rharrowing0@sciencedaily.com
2	2	Marcellus	Jobes	mjobes1@nasa.gov
3	3	Reynold	Dymott	rdymott2@amazon.co.uk
4	4	Suzette	Saphir	ssaphir3@cdc.gov
5	5	Kinny	McCard	kmccard4@dailymail.co.uk

ETL Tools

SQL Server Integration Services

- Terintegrasi dengan SQL server dan Visual studio
- Merupakan aplikasi desktop
- Koneksi data source yang tersedia: OLE DB, ODBC, Flat file, Excel, XML, HDFS, dll

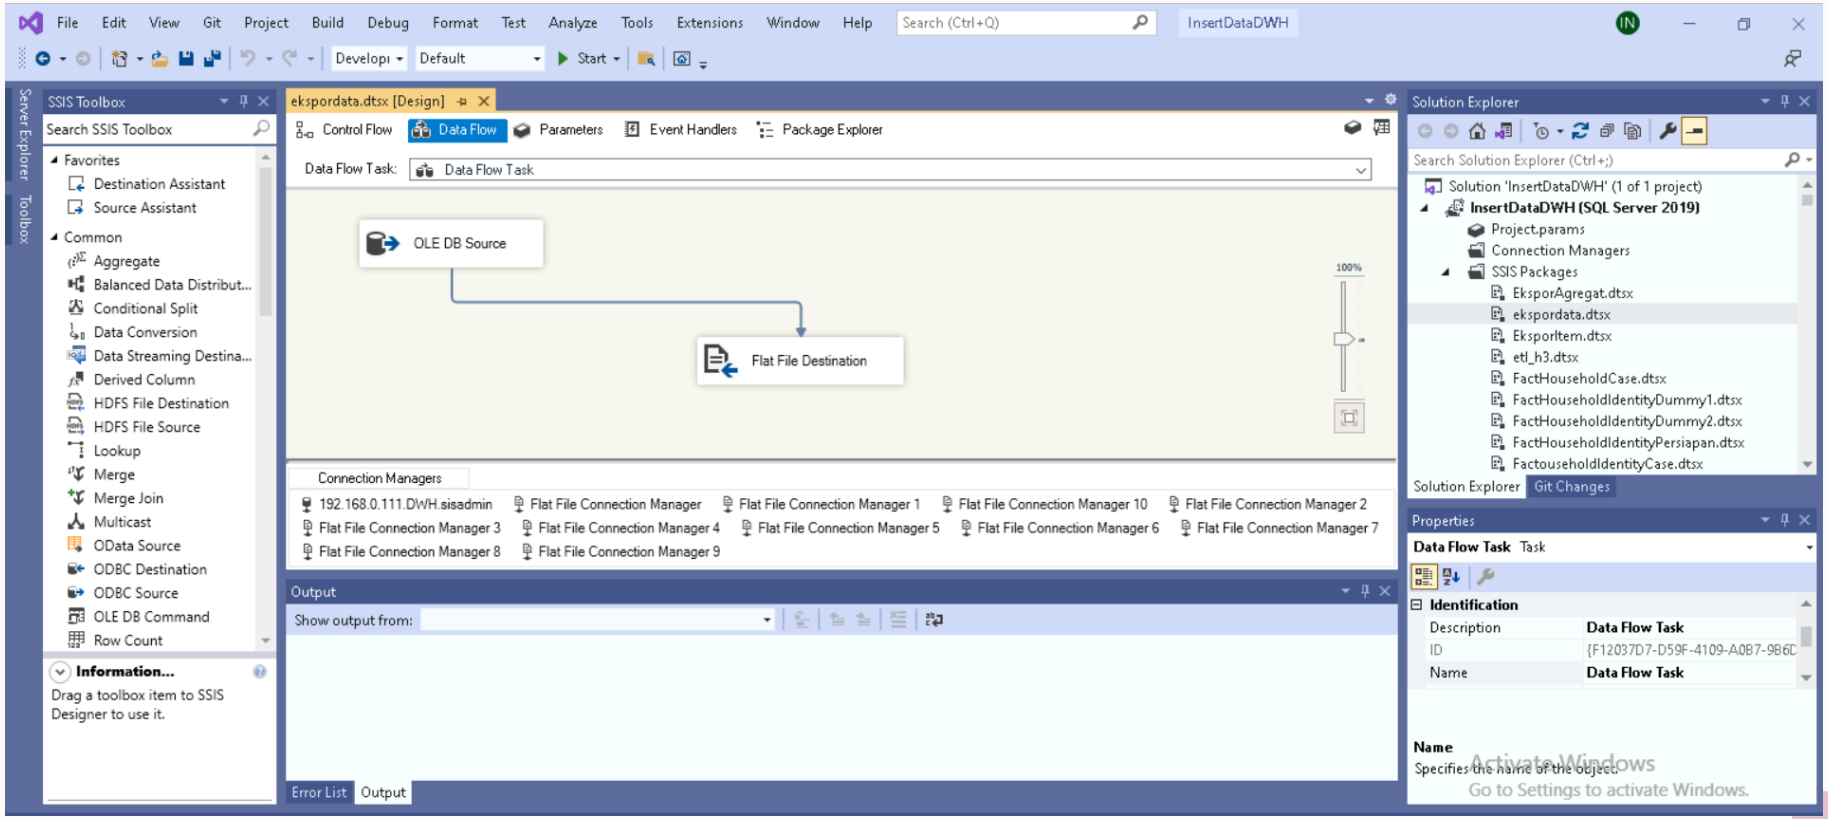

ETL Tools

IBM Data Stage

- Merupakan aplikasi COTS
- Tersedia dalam aplikasi desktop dan web
- Koneksi data source yang tersedia: ODBC, JDBC, File Connector, Sequential File, DB2,

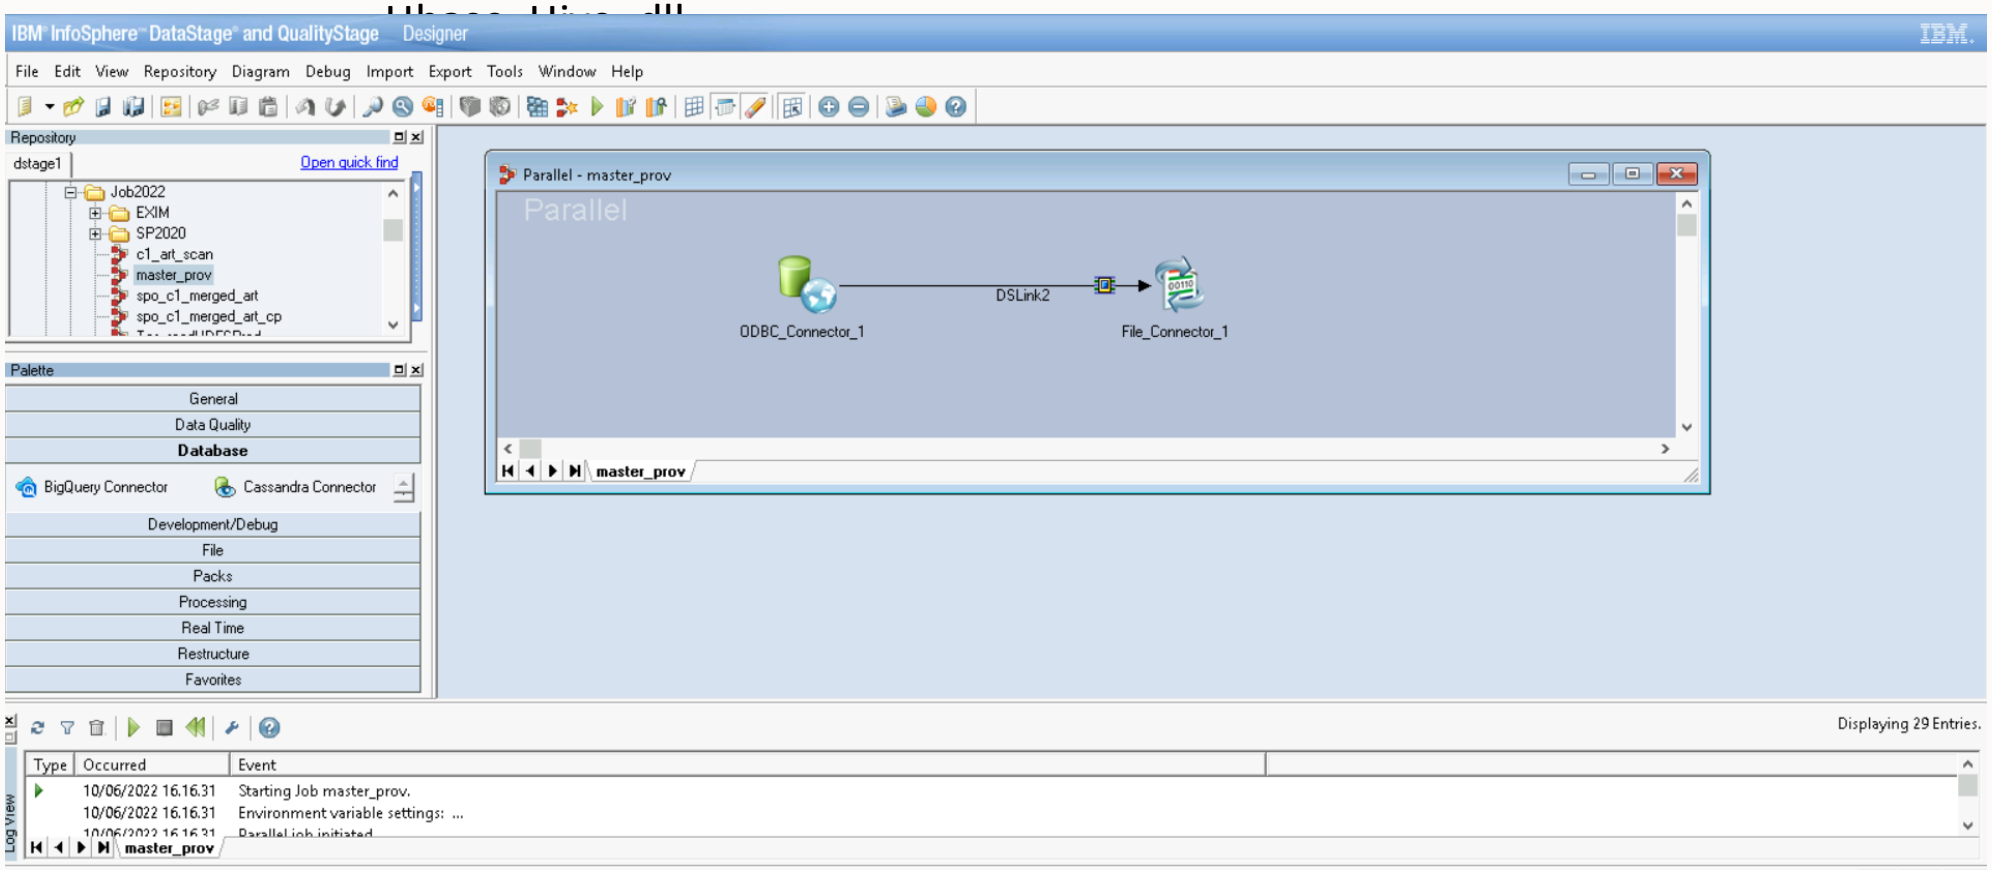

ETL Tools

Apache Air Flow

- Merupakan Open Source
- Tersedia dalam aplikasi web yang dapat digunakan untuk membuat task flow
- Proses ekstraksi, transformasi, dan loading dilakukan dengan menggunakan script python

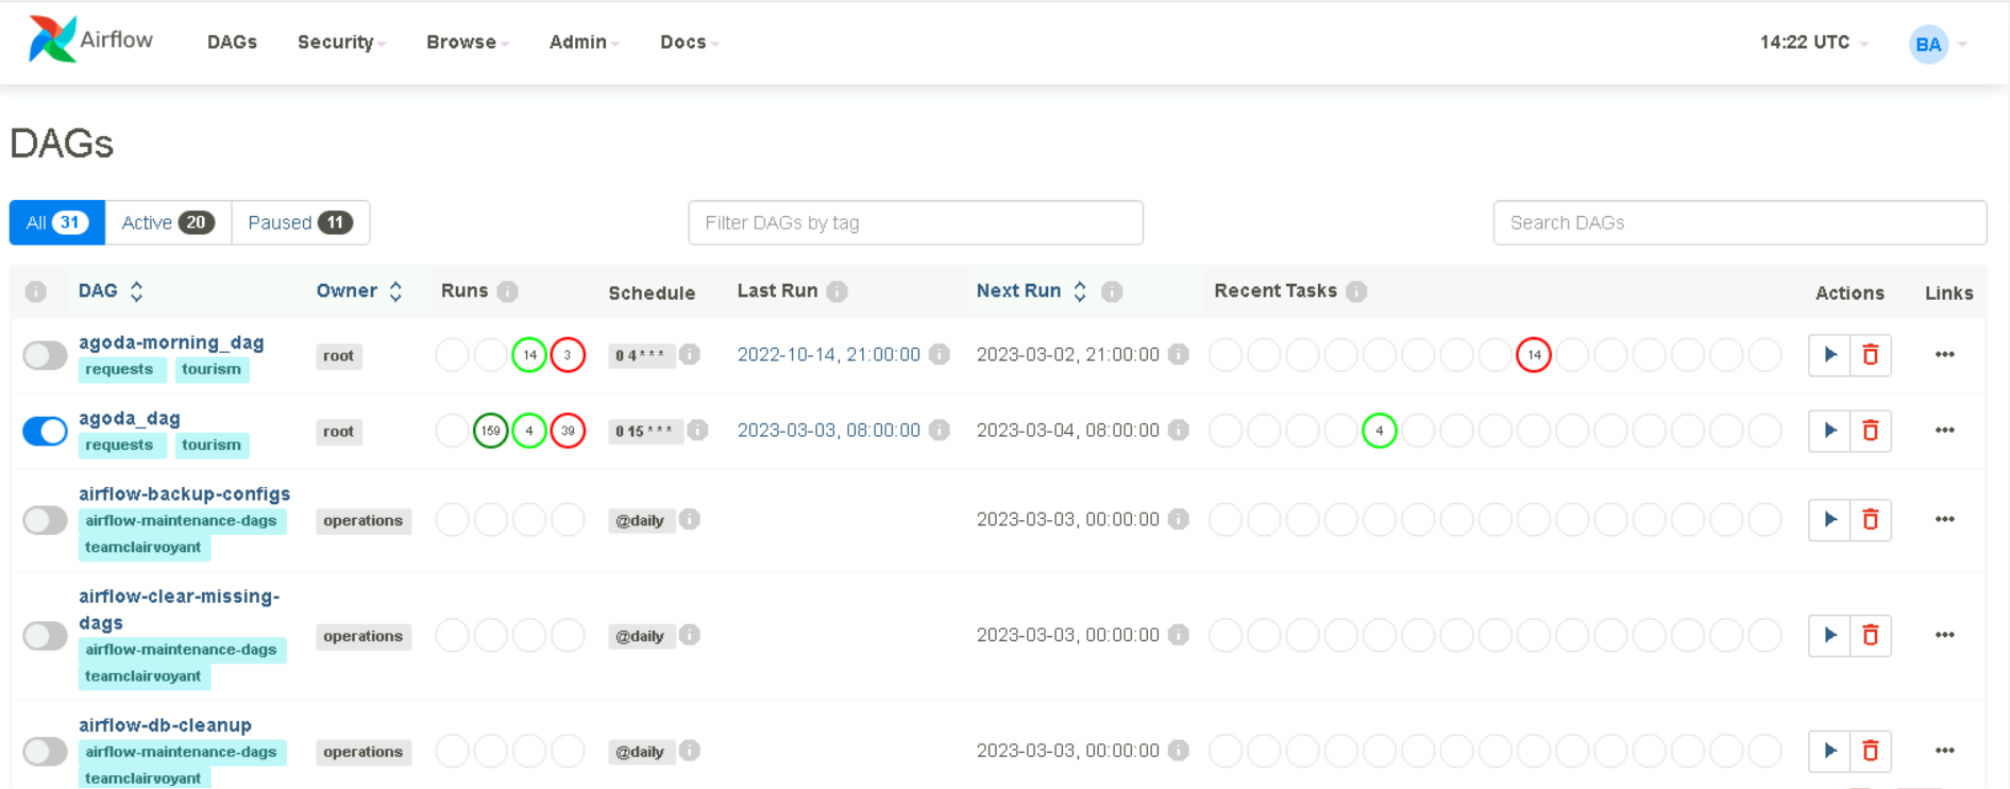

Pengenalan SQL Server Integration Services

- SQL Server Integration Services (SSIS) merupakan platform yang digunakan sebagai solusi untuk integrasi dan transformasi data.
- SSIS dapat dimanfaatkan untuk menyelesaikan permasalahan kompleks, seperti *copy* atau mengunduh file, loading data ke skema warehouse, *cleansing* dan *mining* data, dan pengelolaan objek dan data di SQL Server.
- Kapabilitas:
  - ✓ Ektraksi dan transformasi data
  - ✓ Memiliki sejumlah fitur task dan transformasi
  - ✓ Graphical tools untuk membuat package
  - ✓ Terintegrasi dengan SSIS catalog database untuk menyimpan, menjalankan, dan mengelola *packages*

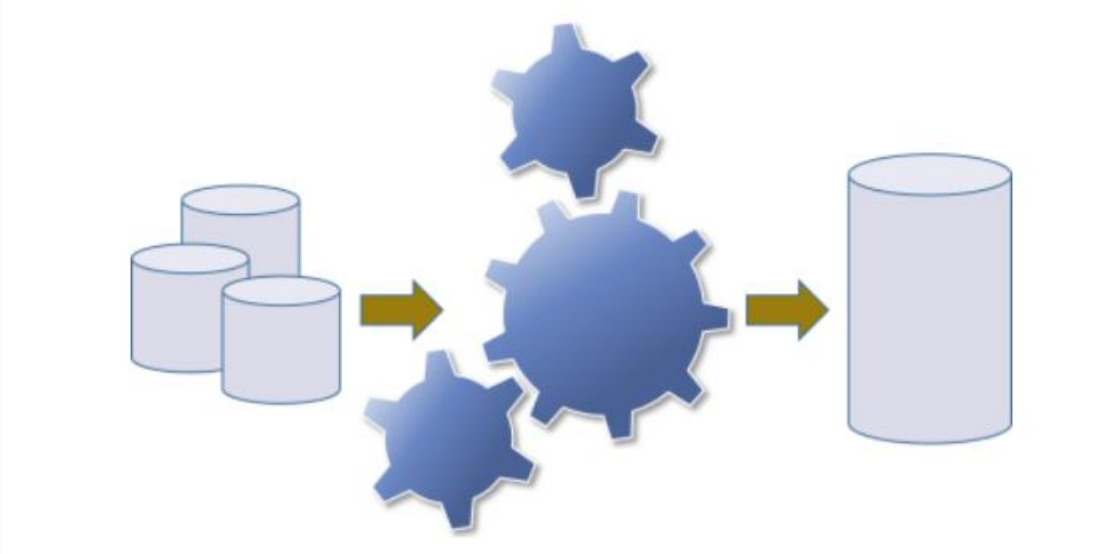

Microsoft® SQL Server® Integration Services

Fitur SSIS

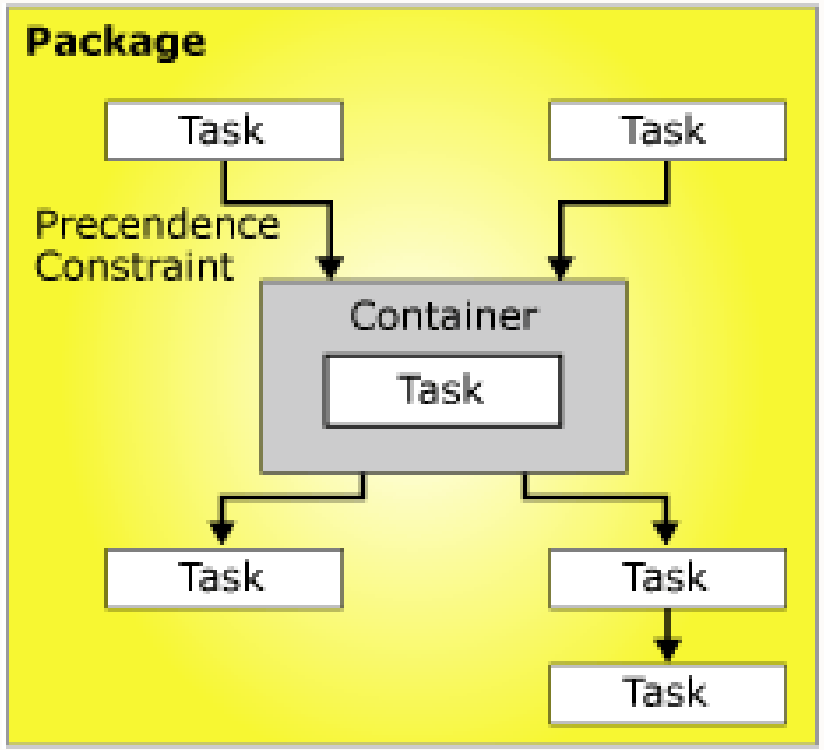

Control Flow

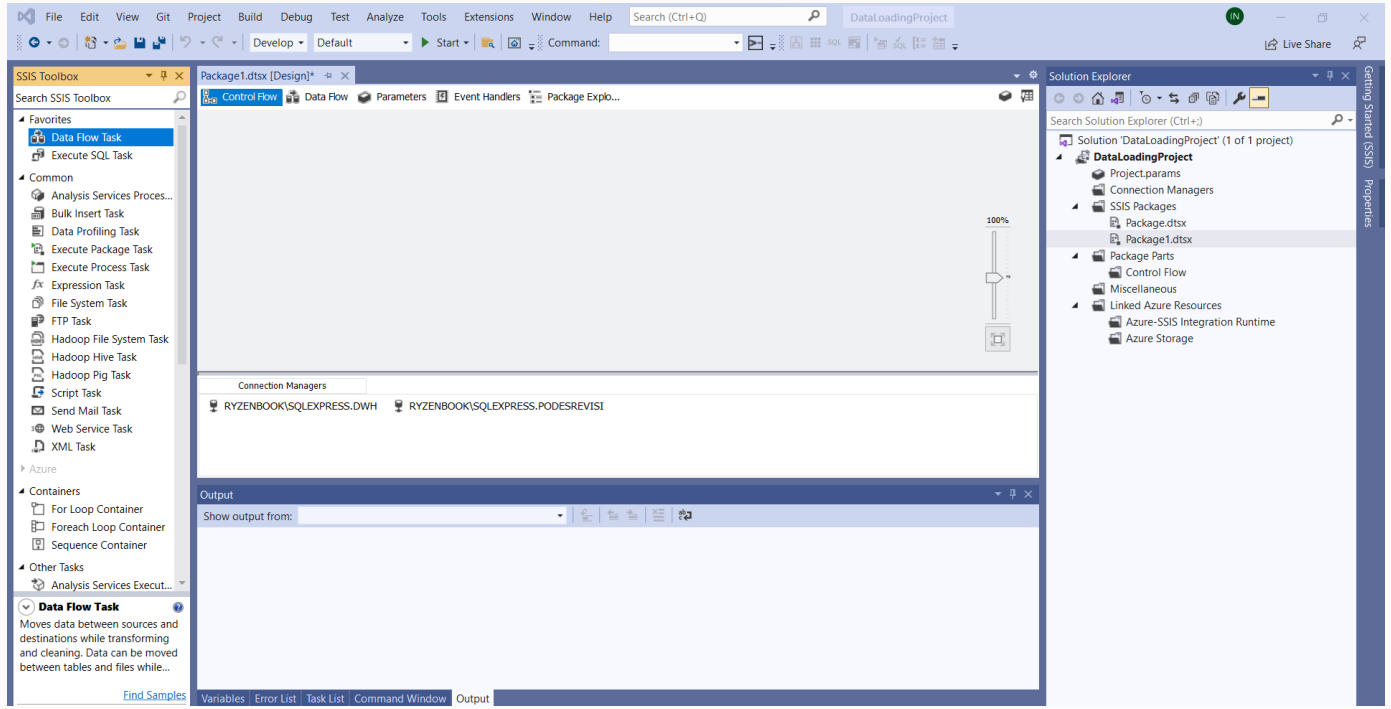

SSIS Designer

Fitur SSIS

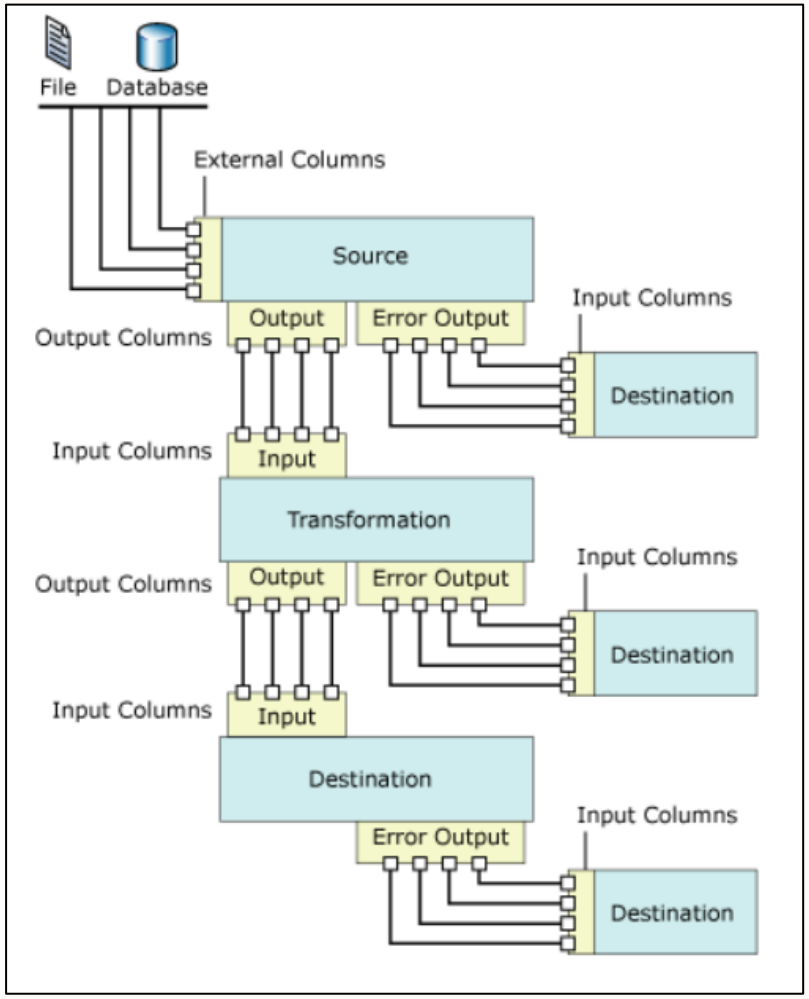

Data Flow

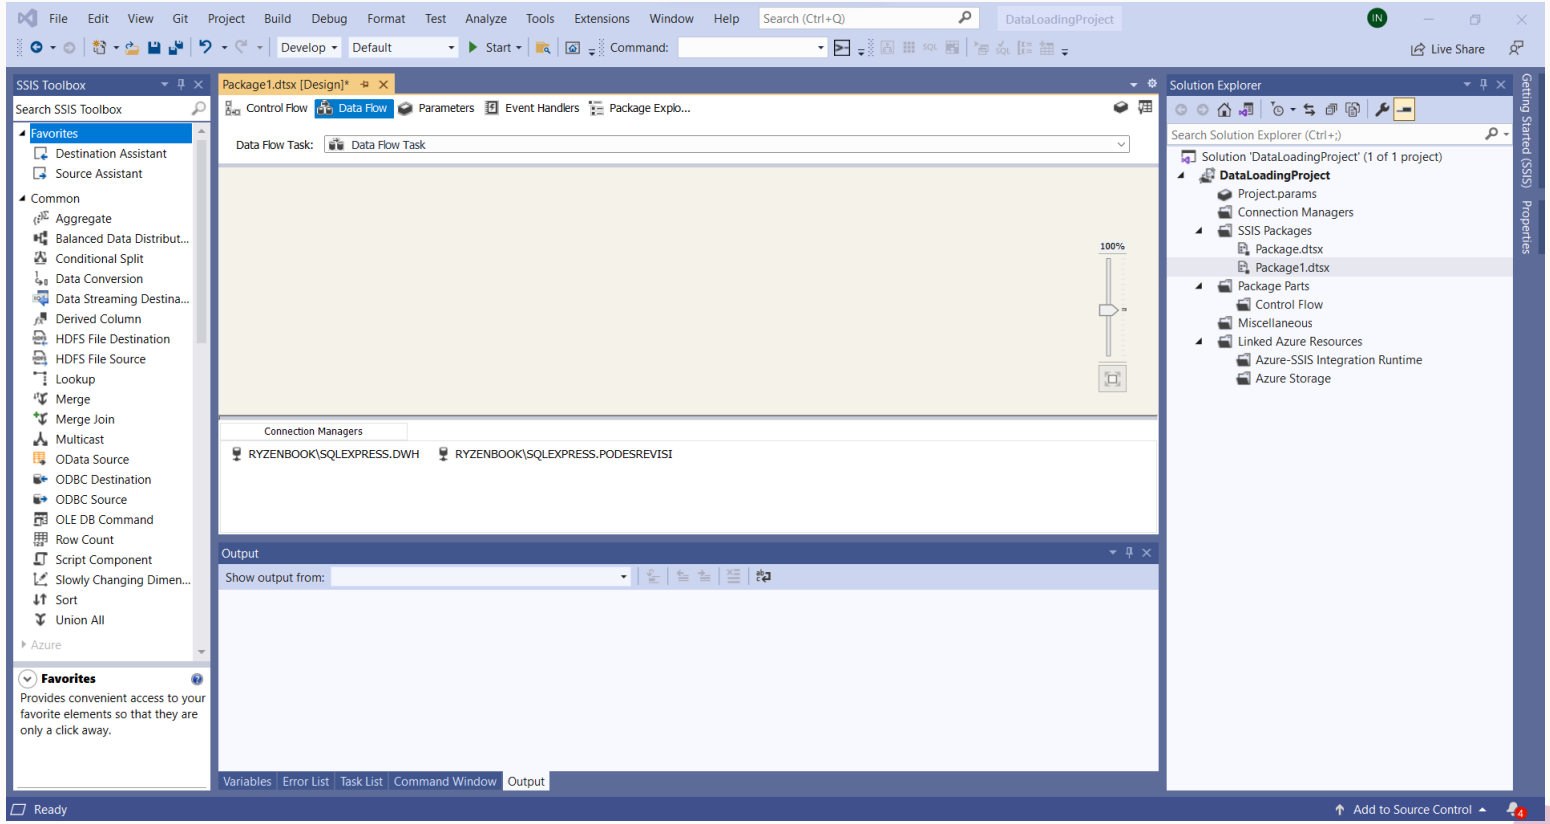

SSIS Designer

Tipe Data Koneksi

- **OLE DB** → Object Linking and Embedding Database
- **ODBC** → Open Database Connecting

criteria	OLEDB	ODBC
Platofrm Support	32/64-bit Windows only	32/64-bit Windows, Linux, Mac, Unix
Product Support	Currently supported in .Net 6. On preview in .Net 7.	Currently supported in .Net 6. On preview in .Net 7. Also supported in UnixODBC iODBC
Database Driver/Provider Support	Fewer providers compared to ODBC but can use ODBC data sources	Most DBMS Systems have ODBC drivers. (This includes major RDBMS, NoSQL like MongoDB, and flat files like CSV, Excel, text file, and more)
Performance	Each provider and data source are different. So, test against ODBC.	Each driver and data source are different. So, test against OLEDB.

OLE DB Connection

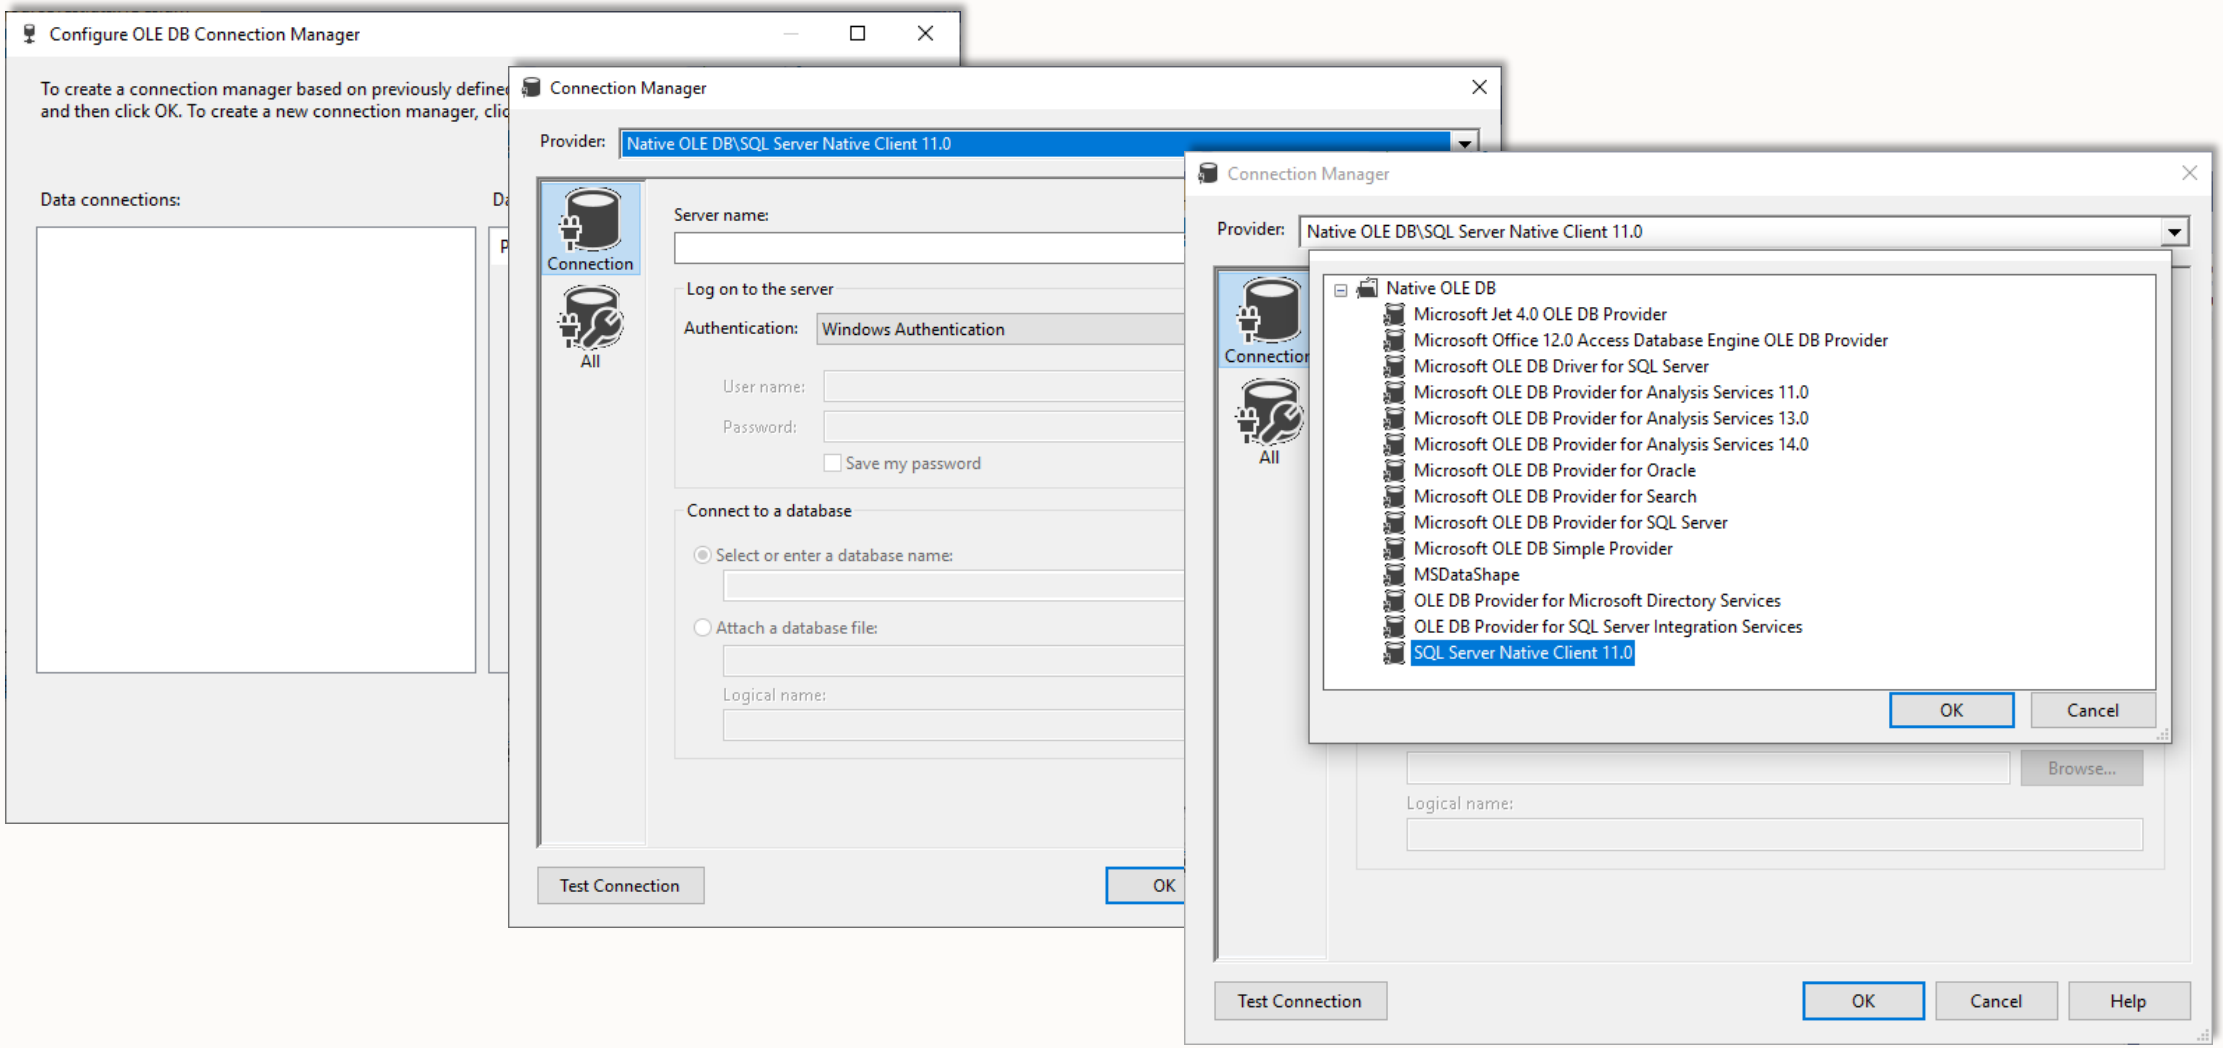

ODBC Connection

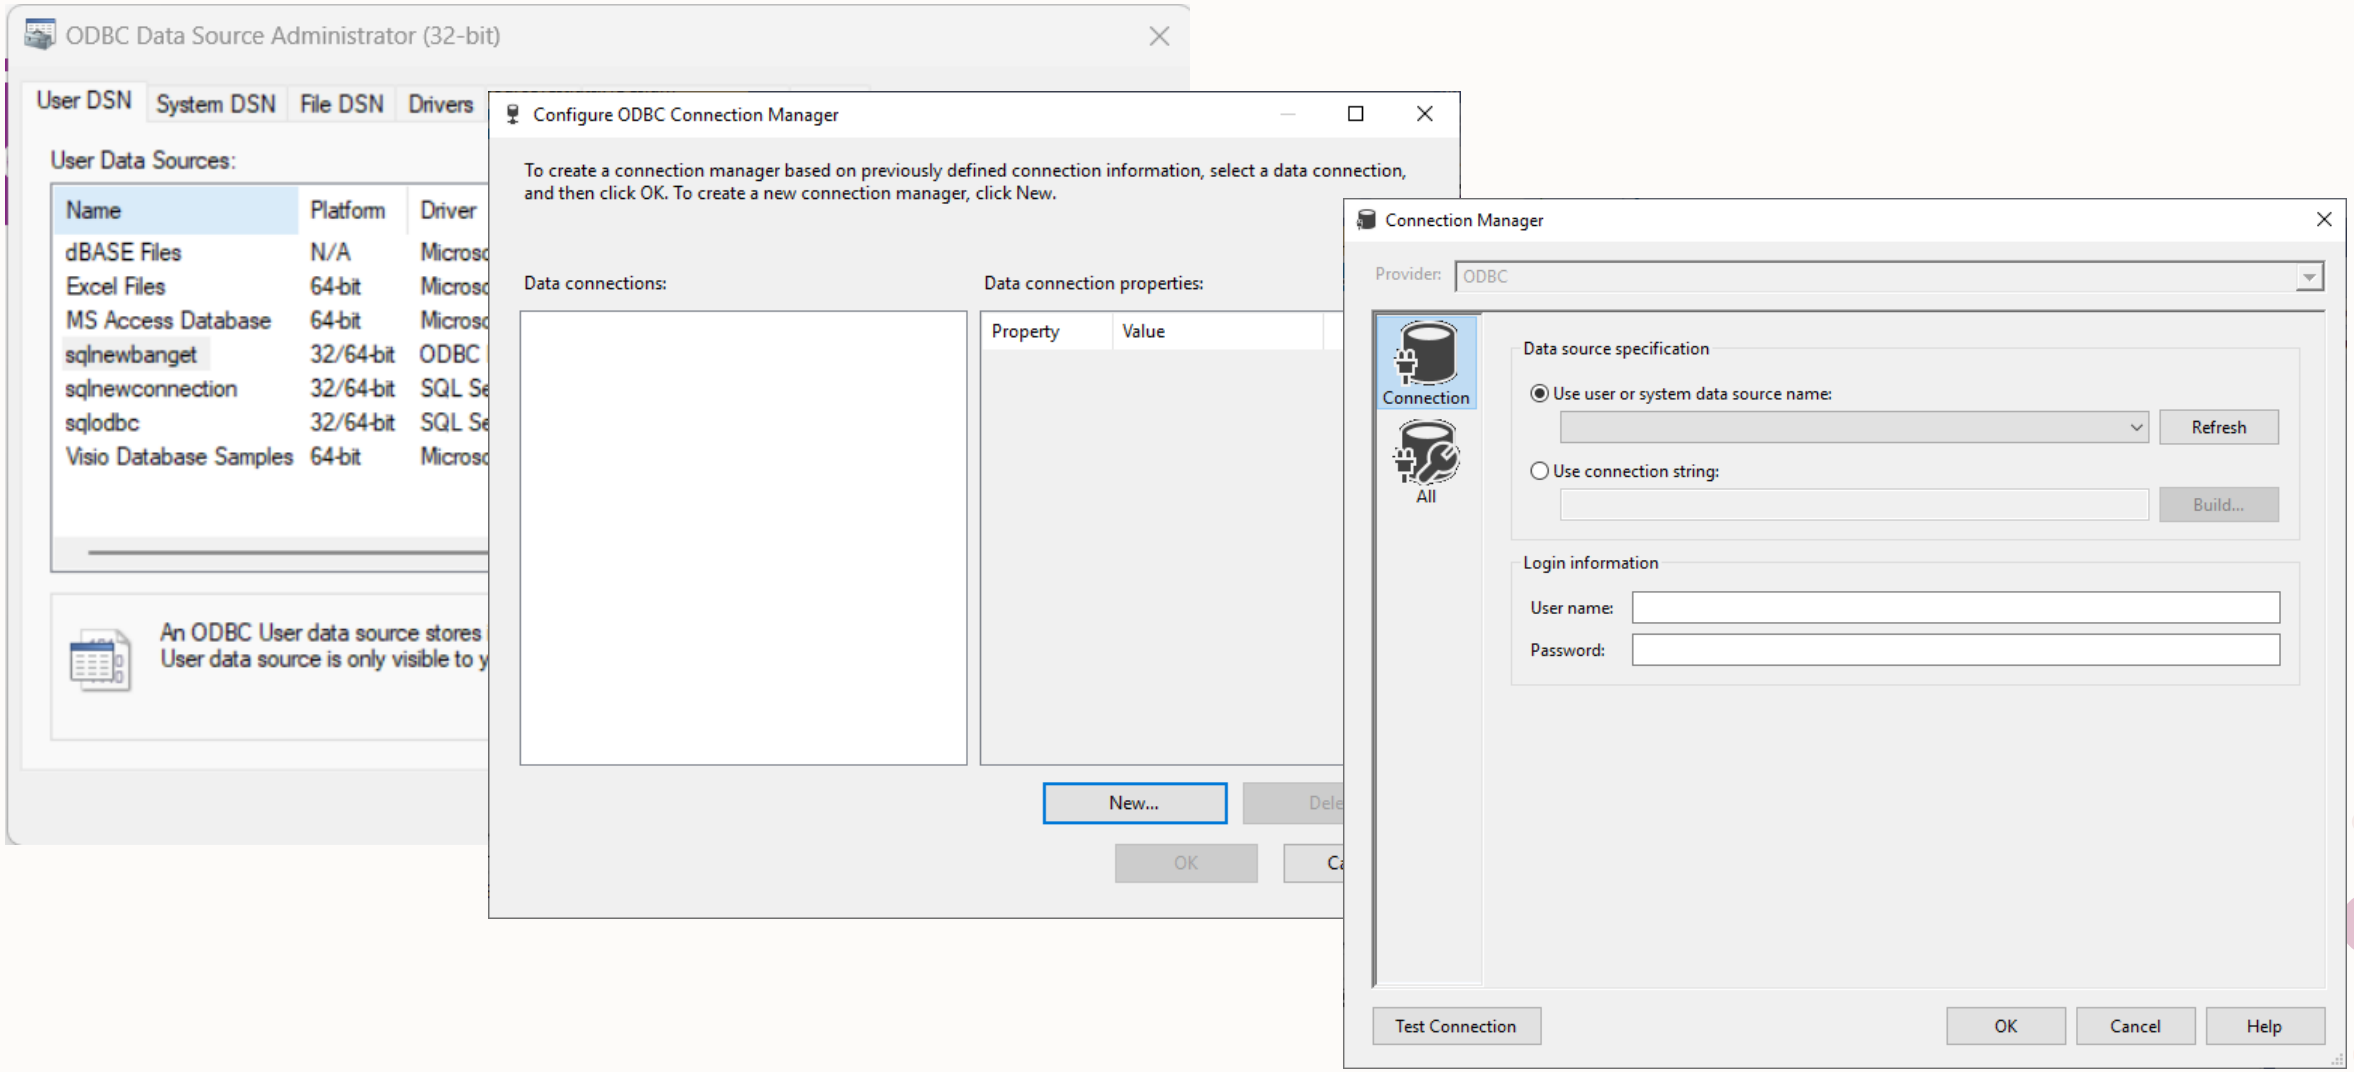

Tips

1. Extraksi data dilakukan secara paralel
2. Ektraksi dilakukan pada data yang memang dibutuhkan
3. Jika kebutuhan ETL cukup dinamis, maka pendekatan, seperti Meta Data driven ETL dan lainnya, dapat dilakukan dibandingkan langsung mendesain semuanya dalam satu kali waktu
4. Hindari penggunaan **Asynchronous transformation components**: Sort, Aggregate, Merge Join, dll
5. Optimalkan penggunaan **event handlers**
6. Pertimbangkan skema tabel tujuan saat akan me-*load* data dalam ukuran besar
7. Konfigurasi *property* dari komponen, misal MaxCurrentExecutables dan EngineThreads
8. Konfigurasi **Data access mode option** pada koneksi OLE DB
9. Konfigurasi **Rows per Batch** dan **Maximum Insert Commit Size** pada OLE DB Desrination
10. Hindari typecast yang implisit

Sumber: Top 10 Methods to Improve ETL Performance Using SSIS | Developer.com

Implementasi (Demo)

Persiapan Praktik

1. Instalasi SQL Server dan Visual Studio
2. Melakukan modifikasi pada visual studio untuk menambahkan SSDT (SQL Server Data Tools)
3. Menambahkan add-on/extension Integration Services pada visual studio
4. Membuat project Integration Services

Case

1. Data yang digunakan adalah: imdb_data.csv
2. Penyiapan skema tujuan
3. Operasi yang dilakukan
   - ✓ a. Ektraksi data
   - ✓ b. Transformasi data
   - ✓ c. Load Data
4. Melihat hasil dari data yang telah di-load

Terima kasih