LAPORAN UJIAN TENGAH SEMESTER
TEKNOLOGI PEREKAYASAAN DATA

Implementasi *Pipeline* ETL dan Pemrosesan Analitik (OLAP) untuk Pemetaan Risiko Rantai Pasok Daging Nasional

Disusun Oleh :

KELOMPOK 1 (3SI1)

Anggita Cristin Meylani	222312982
Clarisse De Delgada M. Soares	222313033
M Rezky Raya Kilwouw	222313190
Nyimas Virna S. L. R	222313307

POLITEKNIK STATISTIKA STIS

TAHUN AJARAN 2025/2026

PENDAHULUAN

1.1 Latar Belakang

Sebagai negara dengan populasi lebih dari 278 juta jiwa, pemenuhan kebutuhan protein hewani khususnya dari komoditas sapi dan ayam merupakan pilar utama dalam menjaga ketahanan pangan nasional Indonesia. Rantai pasok peternakan merupakan ekosistem yang sangat dinamis dan rentan terhadap berbagai guncangan. Stabilitas pasokan dan harga di pasar dapat dengan mudah terganggu oleh berbagai faktor risiko, mulai dari fluktuasi permintaan musiman, defisit ketersediaan karkas di tingkat rumah potong hewan, hingga ancaman wabah penyakit hewan menular yang dapat menurunkan produktivitas populasi ternak secara drastis dalam waktu yang singkat.

Dalam upaya memantau dan memitigasi risiko-risiko tersebut, pemerintah dan pemangku kepentingan masih dihadapkan pada kendala arsitektur informasi yang terfragmentasi atau *data silo*. Saat ini, informasi krusial tersebar di berbagai instansi dengan format, platform, dan tingkat granularitas yang berbeda-beda. Data demografi dan ketersediaan populasi ternak dikelola oleh Badan Pusat Statistik (BPS), data pemantauan kesehatan hewan, arus mutasi logistik, dan realisasi pemotongan tercatat dalam basis data iSIKHNAS, sementara fluktuasi harga komoditas harian di pasar retail dipantau melalui Pusat Informasi Harga Pangan Strategis (PIHPS).

Keterisolasian sumber-sumber data ini mengakibatkan proses identifikasi dan analisis akar masalah volatilitas harga pangan menjadi sangat lambat dan bias. Pengambil kebijakan seringkali kesulitan mendeteksi apakah lonjakan harga daging di tingkat konsumen murni disebabkan oleh spekulasi pasar, atau merupakan dampak sistemik dari kegagalan pasokan akibat merebaknya penyakit di wilayah asal. Tanpa adanya visibilitas data yang komprehensif yang menghubungkan peristiwa di hulu dengan hilir, perumusan kebijakan ketahanan pangan cenderung bersifat reaktif. Kondisi ini menunjukkan ketiadaan sistem peringatan dini (*early warning system*) yang esensial untuk mengantisipasi krisis sebelum dampaknya membebani daya beli masyarakat.

Menjawab tantangan tersebut, proyek *Livestock Intelligence* ini diinisiasi untuk merancang dan mengimplementasikan sebuah ekosistem *Data Warehouse* yang terintegrasi. Melalui arsitektur *pipeline* berbasis *Extract, Transform, Load* (ETL), sistem ini secara otomatis mengekstraksi, membersihkan, dan menyatukan sumber data yang heterogen, baik dari sistem

API, basis data relasional, maupun dokumen *spreadsheet* ke dalam satu wadah penyimpanan terpusat. Transformasi data ini secara ketat menyelaraskan identitas wilayah, dimensi waktu, dan jenis komoditas, sehingga batasan struktural antarinstansi dapat dilebur untuk memfasilitasi pemrosesan analitik secara multidimensi (*Online Analytical Processing* / OLAP).

Dengan terintegrasinya data secara utuh dari hulu ke hilir, sistem ini tidak hanya berfungsi sebagai pusat repositori historis, tetapi juga menjadi instrumen analitik prediktif. Proyek ini memformulasikan *Supply Risk Index* (SRI) sebagai indikator komposit yang memetakan kerentanan pasokan, serta menganalisis korelasi jeda waktu (*time-lag*) secara saintifik antara intensitas wabah dengan kenaikan harga pasar. Melalui penyajian metrik yang akurat ke dalam *dashboard* interaktif, proyek ini memfasilitasi transformasi manajemen logistik peternakan menuju pengambilan kebijakan berbasis data (*data-driven policy*) demi menjaga stabilitas dan kedaulatan pangan nasional secara berkelanjutan.

1.2 Tujuan Proyek

Tujuan proyek ini dapat dijabarkan sebagai berikut.

1. Membangun Data Warehouse terintegrasi melalui mekanisme Extract Transform Load untuk menyatukan sumber data logistik dan harga yang terfragmentasi.
2. Mengimplementasikan pemrosesan analitik daring (OLAP) ke dalam dashboard interaktif guna memfasilitasi eksplorasi data secara multidimensi.
3. Membangun indikator prediktif Supply Risk Index yang mengkalkulasi tren fluktuasi harga, dampak wabah, dan tekanan pasokan sebagai sistem peringatan dini bagi pemerintah.
4. Menganalisis korelasi antara lonjakan kasus penyakit di daerah produsen dengan tren kenaikan harga pasar untuk membuktikan akar penyebab volatilitas harga.
5. Mengukur ketimpangan antara kebutuhan permintaan daging dengan realisasi pengiriman fisik ternak untuk mengidentifikasi besaran defisit pasokan di wilayah konsumen.
6. Memetakan kerentanan logistik secara spasial dengan membandingkan lokasi penyebaran penyakit terhadap kepadatan populasi ternak guna menentukan prioritas alokasi pencegahan wabah.
7. Mengevaluasi tingkat desentralisasi wilayah produsen terhadap total pasokan nasional untuk mengukur tingkat kerentanan pangan apabila terjadi guncangan rantai pasok.

ARSITEKTUR DAN METODOLOGI PIPELINE

2.1 Arsitektur Pipeline

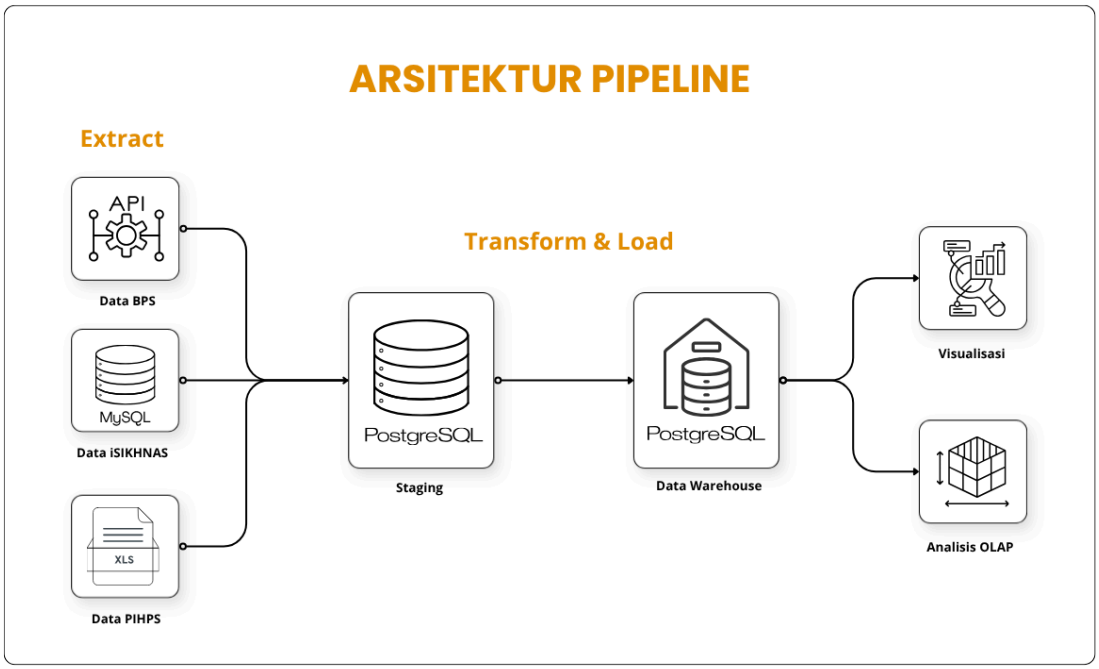

2.3 Penjelasan Tahapan ETL

2.3.1 Penggunaan Scheduler/Orchestrator (Apache Airflow)

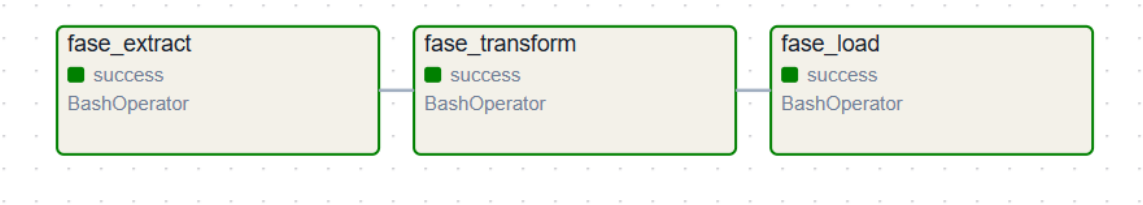

Untuk memastikan seluruh tahapan *Extract, Transform*, dan *Load* (ETL) berjalan secara terotomatisasi, sistematis, dan sesuai dengan urutan logisnya, proyek ini menggunakan Apache Airflow sebagai alat orkestrasi data. Seluruh alur kerja didefinisikan ke dalam sebuah DAG dengan nama livestock_intelligence_etl_final.

1) Arsitektur Eksekusi Cross-Environment

Pada proyek ini, server airflow berjalan di dalam ekosistem Linux (WSL/Ubuntu), sementara skrip Python dan PySpark dikonfigurasi pada ekosistem Windows, sehingga DAG dirancang dengan metode eksekusi hybrid. Airflow memanggil *interpreter* Python di lingkungan Windows melalui titik lebur *path* WSL, lalu mengeksekusi *path* skrip berformat Windows murni.

```
# Konfigurasi Path Lintas Sistem Operasi
PYTHON_BIN = "/mnt/c/Users/.../.venv/Scripts/python.exe"
CODE_DIR_WIN = r"C:\Users\...\CODE"

# Implementasi pemanggilan hybrid pada Task (extract)
t_extract = BashOperator(
   task_id="fase_extract",
   bash_command=f'export PYTHONIOENCODING=utf-8 && "{PYTHON_BIN}"
"{CODE_DIR_WIN}\\EXTRACT\\extract.py"',
)
```

2) Penjadwalan dan Toleransi Kegagalan

DAG ini diatur dengan argumen bawaan (default_args) untuk menjaga stabilitas *pipeline*. Dilakukan penjadwalan proses dieksekusi yakni setiap hari (schedule='@daily') tanpa menjalankan histori masa lalu yang terlewat (catchup=False). Jika terjadi kegagalan, Airflow akan secara otomatis melakukan *retry* sebanyak 1 kali dengan jeda 3 menit.

```
default_args = {
    "owner":            "kelompok1_tpd",
    "depends_on_past":  False,
    "start_date":       datetime(2026, 5, 1),
    "retries":          1,
    "retry_delay":      timedelta(minutes=3),
    "email_on_failure": False,
}

with DAG(
    dag_id="livestock_intelligence_etl_final",
    default_args=default_args,
```

```
    description="ETL Pipeline TPD Kelompok 1 (Extract, Transform,
Load)",
    schedule= '@daily',
    catchup=False,
    tags=["UTS", "TPD", "Kelompok1"],
) as dag:
```

3) Dependency Graph

Pipeline menggunakan BashOperator untuk mengeksekusi tiga task (t_extract, t_transform, dan t_load). Dependency Graph didefinisikan untuk menjamin eksekusi sekuensial dan memastikan bahwa fase *Transform* dan *Load* tidak akan pernah berjalan jika fase sebelumnya gagal.

```
# Dependency Graph (Eksekusi Sekunsial)
t_extract >> t_transform >> t_load
```

2.3.2 Extract

Tahap ekstrak merupakan proses pengambilan data mentah dari beberapa sumber yang berbeda format dan media penyimpanannya, lalu memindahkannya ke dalam area penampungan sementara (staging area). Tahapan ini terdiri atas:

1) **Ekstraksi Data BPS**

Data BPS diperoleh melalui scraping API dari web API yang disediakan oleh BPS secara otomatis. Variabel yang diekstraksi meliputi nama provinsi, tahun, jumlah penduduk (jiwa), populasi sapi dan ayam (ekor), dan produksi daging ayam (kg). Produksi daging sapi tidak tersedia melalui API BPS sehingga nilainya dibangkitkan melalui data simulasi (dummy) pada tahap berikutnya.

```
# Fungsi inti mengambil data dari endpoint API BPS
def _get(year: int, table_id: str, kode_wilayah: str = "0000000")
    url = (
f"https://webapi.bps.go.id/v1/api/interoperabilitas/datasource/sim
dasi/"
```

```
f"id/25/tahun/{year}/id_tabel/{table_id}/wilayah/{kode_wilayah}/ke
y/{API_KEY}")
        r = requests.get(url, timeout=30)
        return r.json()

    # Menyimpan hasil scrape mentah ke PostgreSQL
staging_db
df_scraped.to_sql('staging_bps_api_raw', engine_staging,
if_exists='replace', index=False)
```

2) **Pembuatan Data Dummy**

Untuk melengkapi parameter analisis yang tidak tersedia di BPS, sistem membangkitkan data simulasi seperti seperti jumlah konsumsi daging sapi dan ayam (kg per kapita), jumlah permintaan daging sapi dan ayam (ekor), jumlah sapi dan ayam yang dipotong (ekor), harga baseline daging sapi dan ayam (rupiah), dan growth populasi.

```
# Pembangkitan data menggunakan random uniform dan randint
 growth = round(random.uniform(-0.02, 0.04), 4)
 konsumsi_sapi = round(random.uniform(1.5, 3.5), 2)
 harga_sapi = random.randint(90000, 130000)
# Memasukkan data dummy ke area penampungan
 df_bps_dummy_raw.to_sql('staging_bps_dummy_raw', engine_staging,
if_exists='replace', index=False)
```

3) **Ekstraksi data iSIKHNAS**

Data iSIKHNAS merupakan data kesehatan dan lalu lintas hewan yang telah tersedia dalam database MySQL. Seluruh enam dari database tersebut ditarik dan disalin utuh ke dalam staging area. Data ini terdiri atas beberapa tabel, yaitu tabel hewan, wilayah, data mutasi ternak antarwilayah, laporan penyakit, hasil uji laboratorium, dan data pemotongan di rumah potong hewan (RPH).

```
# List tabel yang ditarik dari MySQL (iSIKHNAS)
 ISIKHNAS_TABLES = ["ref_hewan","ref_wilayah", "tr_mutasi",
```

```
"tr_laporan_sakit", "tr_hasil_lab", "tr_rph"]
 for table in ISIKHNAS_TABLES:
    try:
        df_isikhnas = pd.read_sql(f"SELECT * FROM {table}",
engine_isikhnas)
        staging_table_name = f"staging_isikhnas_{table}"
        df_isikhnas.to_sql(staging_table_name, engine_staging,
if_exists='replace', index=False)
```

4) Ekstraksi data PIHPS

Data harga komoditas pasar yang tersimpan dalam format Excel (.xlsx) diunduh dan dipindahkan ke dalam staging_db tanpa mengubah struktur kolom aslinya. Data PIHPS memuat informasi harga komoditas daging per provinsi, jenis pasar (tradisional, modern, pedagang besar), serta waktu pencatatan.

```
# Ekstrasi file Excel PIHPS
 if os.path.exists(PIHPS_FILE):
    try:
        df_pihps = pd.read_excel(PIHPS_FILE)
        df_pihps.to_sql("staging_pihps_raw", engine_staging,
if_exists='replace', index=False)
```

2.3.3 Transform

Pada tahap transform, data mentah dibersihkan, distandardisasi, dan dibentuk ulang agar memiliki struktur relasional yang seragam sebelum masuk ke *Data Warehouse*. Tahapan ini terdiri atas:

1) *Cleaning & Merge* Data BPS

Data BPS yang ditarik melalui API masih berformat teks mentah dengan standar penulisan numerik Indonesia (titik sebagai pemisah ribuan dan koma sebagai desimal). Sebelum dapat dihitung, sistem melakukan pembersihan menggunakan ekspresi reguler (*RegEx*) untuk menghapus tanda titik dan mengubah koma menjadi titik, lalu melakukan

casting ke tipe data Double. Setelah bersih, data API digabungkan (*Inner Join*) dengan data *dummy* BPS.

```
def clean_bps_num(df, col_name: str):
    return (df
        .withColumn(col_name,F.regexp_replace(F.col(col_name),
r'\.', ''))
        .withColumn(col_name,F.regexp_replace(F.col(col_name),
',', '.'))
        .withColumn(col_name, F.col(col_name).cast(DoubleType()))
    )
# Merge API dan Dummy
 sdf_bps_master = (sdf_bps_api_clean.alias("api")
    .join(
        sdf_bps_dummy_clean.alias("dum"),on=["provinsi", "tahun"],
how="inner")
```

2) Normalisasi dan Unpivot Data BPS

Data BPS yang awalnya memiliki format melebar (*wide*) kemudian dipecah menjadi empat tabel terpisah untuk menyelaraskan tingkat granularitasnya dengan data sistem lain. Proses ini dilakukan dalam beberapa langkah yakni:

a. Pembuatan Tabel Referensi

Sistem mengekstrak daftar unik provinsi untuk membuat tabel ref_wilayah dan mengidentifikasi daftar komoditas ke dalam ref_komoditas, di mana keduanya dilengkapi dengan primary *key bertipe* integer.

b. Penyutinan ID (Mapping)

Setelah ref_wilayah berhasil dibuat, sistem menyuntikan id_wilayah kemabli ke tabel utama BPS melalui proses JOIN berdasaekan teks nama provinsi. Setelah ID angka berhasil ditransfer masuk, kolom teks nama provinsi pada tabel utama dihapus.

c. Pemisahan dan Unpivot

Atribut demografi kependudukan dipisahkan ke dalam tabel tr_demografi. Sementara itu, kolom spesifik hewan seperti populasi dan produksi dilebur (Unpivot/Melt)

menjadi struktur baris memanjang ke bawah ke dalam di dalam tabel tr_statistik berdasarkan komoditasnya.

```
# Ekstrak daftar provinsi unik dan buat ref_wilayah
 window_prov = Window.orderBy("provinsi")
 sdf_ref_wilayah_bps = (sdf_bps_master
    .select("provinsi").distinct()
    .orderBy("provinsi")
    .withColumn("id_wilayah", F.row_number().over(window_prov))
)
# Suntik id_wilayah ke master BPS dan hapus kolom teks provinsi
sdf_bps_mapped = (sdf_bps_master.alias("bps")
       .join(sdf_ref_wilayah_bps.alias("ref"), on="provinsi", how="left")
       .drop("provinsi")
)
# Unpivot menjadi tr_statistik (mengabungkan kolom Sapi dan Ayam)
 sdf_sapi = (sdf_bps_mapped.select("id_wilayah", "tahun",
    F.lit(1).alias("id_komoditas"),
    F.col("populasi_sapi_dummy")).alias("populasi"))
sdf_ayam = (sdf_bps_mapped.select("id_wilayah", "tahun",
    F.lit(2).alias("id_komoditas"),
    F.col("populasi_ayam_dummy")).alias("populasi"))
sdf_tr_statistik = sdf_sapi.unionByName(sdf_ayam)
```

3) Preprocessing Lanjutan

Selanjutnya, dilakukan standardisasi penamaan wilayah dari semua sumber data agar selaras dengan nama resmi BPS menggunakan *mapping dictionary* berpadu dengan fungsi *trim* dan *upper*. Atribut tanggal dikonversi menjadi tipe Date dan diekstrak menjadi elemen bulan serta tahun. Pada tahap ini juga dilakukan imputasi missing value pada pada harga komoditas dengan menerapkan metode imputasi tiga lapis (nilai asli ->

nilai median bulan sebelumnya dari wilayah yang sama -> median global) dengan memanfaatkan *Window Function*.

```
# Standardisasi Provinsi bia Mapping Dictionary (Fungsi Trim & Upper)
map_expr = F.create_map([F.lit(x) for pair in pihps_ke_bps.items() for x in pair])

sdf_pihps_clean = (sdf_pihps
    .withColumn("waktu",  F.col("waktu").cast(TimestampType()))
    .withColumn("tgl",    F.to_date(F.col("waktu")))
    .withColumn("bulan",  F.month(F.col("waktu")).cast(IntegerType()))
     .withColumn("tahun",   F.year(F.col("waktu")).cast(IntegerType()))
    .withColumn("harga",  F.col("harga").cast(DoubleType()))

# Harmonisasi Tanggal & Ekstrasi Elemen Waktu
def parse_isikhnas_date(df, col_in: str, col_out: str = None):
    """Parse tanggal iSIKHNAS MM/dd/yy -> DATE, tambah kolom bulan & tahun."""
    out = col_out or col_in
    return (df
                .withColumn(f"_{out}_str",  F.to_date(F.col(col_in), "MM/dd/yy"))
               .withColumn(f"_{out}_str4",  F.to_date(F.col(col_in), "MM/dd/yyyy"))
                 .withColumn(out,  F.coalesce(F.col(f"_{out}_str"), F.col(f"_{out}_str4"))
)
# Imputasi tiga lapis menggunakan Window Function
sdf_laporan_clean = parse_isikhnas_date(sdf_laporan, "tgl_lapor", "tgl_lapor")
sdf_laporan_clean = (sdf_laporan_clean
.withColumn("id_wilayah", F.col("id_wilayah").cast(IntegerType()))
```

```
.withColumn("jumlah_gejala",F.col("jumlah_gejala").cast(DoubleType
()))
.withColumn("jumlah_mati",F.col("jumlah_mati").cast(DoubleType()))
#    Definisi  jendela  untuk  mencari  nilai  terakhir  yang
tersedia
window_median_fallback                                          =
Window.partitionBy("id_wilayah","id_komoditas").orderBy("tahun","b
ulan")

sdf_with_prev_median = (sdf_integrated
    .join(sdf_global_median, on="id_komoditas", how="left")
    .withColumn("prev_harga_median",F.last(F.col("avg_harga"),
ignorenulls=True)
.over(window_median_fallback.rowsBetween(Window.unboundedPreceding
, -1))
    )
    .withColumn("avg_harga",F
    .when(F.col("avg_harga").isNotNull(), F.col("avg_harga"))
    .when(F.col("prev_harga_median").isNotNull(),
F.col("prev_harga_median"))
    .otherwise(F.col("global_median_harga"))
    )
    .drop("prev_harga_median", "global_median_harga")
)
```

4) Pembangunan Tabel Dimensional

Tiga tabel dimensi dibangun untuk menjadi acuan dalam fact table:

a. dim_prov:

Tabel ini bertindak sebagai dimensi spasial. Pembentukan dim_prov diawali dengan mengonsolidasikan seluruh variasi penamaan provinsi menggunakan data BPS sebagai referensi standar (master), kemudian digabungkan secara *Full Outer Join* dengan referensi wilayah dari iSIKHNAS. Setelah nama provinsi distandardisasi dan dibersihkan dari duplikasi, sistem akan men- *generate* prov_key (sebagai *Surrogate Key*).

b. dim_komoditas:

Tabel ini adalah dimensi objek observasi yang didefinisikan secara eksplisit di dalam PySpark menggunakan StructType. Tabel ini memetakan dua entitas utama penelitian ke dalam identitas relasional yang seragam, yaitu komoditas Sapi dan komoditas Ayam. Tabel ini dilengkapi juga dengan surrogate key yakni komoditas_key.

c. dim_waktu:

Tabel ini bertindak sebagai dimensi temporal bulanan. Untuk memastikan seluruh titik waktu pada *fact table* memiliki referensi yang utuh (tanpa bolong), dim_waktu dibangun secara generatif menggunakan modul itertools pada Python. Rentang waktu diekstrak secara dinamis dengan mencari nilai tahun_min dan tahun_max dari seluruh *dataset*, kemudian sistem akan membangkitkan kombinasi deret Tahun-Bulan secara otomatis. Setiap baris kemudian diperkaya dengan atribut turunan seperti nama_bulan (Januari–Desember) dan kuartal, serta dilengkapi dengan pengurutan waktu_key sebagai *Surrogate Key* utamanya.

```
# Kontruksi dim_prov
sdf_dim_prov = (sdf_wilayah_master
    .select("provinsi").dropDuplicates().orderBy("provinsi")
    .withColumn("prov_key", F.row_number()
.over(window_dim_prov))
    .withColumn("id_prov", F.col("prov_key"))
    .select("prov_key","id_prov",
        F.col("provinsi").alias("nama_provinsi")
    ))
# Definisi skema komoditas
schema_kom = StructType([
    StructField("komoditas_key", IT(), False),
    StructField("id_komoditas",  IT(), False),
    StructField("nama_komoditas",ST(), True),])
sdf_dim_komoditas = spark.createDataFrame(
    [(1, 1, "Sapi"), (2, 2, "Ayam")],
    schema_kom
```

```
)
# Pembangkitan deret waktu otomatis
waktu_rows = [(y, m) for y in range(tahun_min, tahun_max + 1)
for m in range(1, 13)]
sdf_dim_waktu = (sdf_waktu_base
  .withColumn("waktu_key", F.row_number().over(window_waktu))
  .withColumn("nama_bulan", nama_bulan_expr[F.col("bulan")])
```

5) Mapping Surrogate Key

Sebelum perhitungan dilakukan, sistem harus memastikan semua sumber data dapat berkomunikasi. Data iSIKHNAS dan PIHPS dipetakan ke surrogate key dengan cara yang berbeda. Untuk data PIHPS, sistem mencocokkan teks nama provinsi (setelah distandarisasi ke format BPS) dengan teks pada tabel dim_prov menggunakan string matching. Untuk data iSIKHNAS, pemetaan dilakukan lebih efisien menggunakan id_wilayah bertipe integer yang sudah tersedia secara native di tabel-tabel iSIKHNAS, sehingga tidak memerlukan pencocokan teks. Setelah data cocok, sistem menyuntikkan angka prov_key ke dalam kedua sumber data sehingga seluruhnya terikat pada satu identitas wilayah relasional yang seragam.

```
#Mapping PIHPS ke dim_prov
df_pihps_prov = (sdf_pihps_imputed.alias("p")
    .join(sdf_dim_prov.alias("dp"),
 F.lower(F.trim(F.col("p.provinsi"))) ==
F.lower(F.trim(F.col("dp.nama_provinsi"))),
        how="left" )
```

6) Agregasi dan Konversi Satuan

Pada tahap ini, data iSIKHNAS yang merupakan data harian diagregasi dengan menghitung total jumlah hewan sakit (yang didekati dengan jumlah gejala), hewan mati, volume mutasi, dan realisasi berat karkas. Begitu pula pada data PIHPS yang diagregasi dengan menghitung rata-rata harga pasar. Rata-rata harga ini dikalkulasi secara komposit dengan melebur seluruh tingkat distribusi (pasar tradisional, pasar modern, dan pedagang besar) untuk menciptakan indeks harga makro yang merangkum keseluruhan fluktuasi

ekonomi. Semua agregasi dikelompokkan berdasarkan provinsi, waktu, dan komoditas. Selain itu, dilakukan konversi satuan pada variabel produksi daging sapi dari ton menjadi kilogram (dikali 1000) agar setara dengan metrik komoditas lainnya.

Selanjutnya, data tahunan BPS (seperti produksi dan permintaan daging) dibagi 12 untuk menghasilkan estimasi rasio bulanan. Hal ini agar data agregasi tahunan bisa dibandingkan dengan realisasi bulanan dari iSIKHNAS.

```
# Normalisasi tahunan ke bulanan
 sdf_bps_bulanan = (sdf_bps_dengan_penduduk
      .withColumn("populasi_ternak", F.col("populasi"))
      .withColumn("produksi_daging_kg",F.when(F.col("id_komoditas")
== 1,F.col("produksi_daging") * F.lit(1000.0))
      .otherwise(F.col("produksi_daging")))
```

7) Integrasi dan Feature Engineering

Seluruh hasil agregasi dari iSIKHNAS dan PIHPS digabungkan (INNER JOIN) dengan tabel BPS menggunakan penghubung prov_key dan tahun. Setelah itu, sistem menghitung nilai supply_risk_index yang menrupakan rata-rata dari tiga komponen utama menggunakan rumus:

$$supply\ risk\ index\ = \frac{price\ gap + health\ impact + supply\ strain}{3}$$

Adapun komponen pembentuk indeks tersebut dihitung dengan rincian sebagai berikut.

- Price gap: komponen ini menghitung deviasi harga pasar aktual terhadap acuan dasar pemerintah

$$price\ gap\ = \frac{rata-rata\ harga - harga\ baseline}{harga\ baseline}$$

- Health impact: komponen ini menghitung tingkat keparahan wabah penyakit terhadap total populasi ternak yang tersedia di wilayah tersebut.

$$health\ impact\ = \frac{total\ jumlah\ sakit + total\ jumlah\ mati}{populasi\ ternak}$$

- Supply strain: komponen ini menghitung volumen pengiriman ternak terhadap rata-rata target permintaan bulanan.

$$supply\ strain\ = \frac{total\ volume\ mutasi}{rata-rata\ permintaan\ bulanan\ (ekor)}$$

Sebelum dirata-rata menjadi indeks akhir, diterapkan teknik *min-max scaling* pada hasil kalkulasi masing-masing komponen pembentuk. Hal ini agar batas bawah dan batas atas nilai setiap komponen selalu terkunci pada rentang 0 - 1 tidak adakomponen mendominasi hasil indeks akhir hanya karena memiliki skala nilai asli yang lebih besar.

```
# Intergrasi Data Angregasi dan BPS
 sdf_integrated = (sdf_agg_all.alias("agg")
    .join(sdf_bps_bulanan.alias("bps"),
        on=[
           F.col("agg.id_wilayah")    == F.col("bps.id_wilayah"),
           F.col("agg.id_komoditas") == F.col("bps.id_komoditas"),
           F.col("agg.tahun")         == F.col("bps.tahun"),],
        how="inner")
# Perhitungan komponen Raw
 sdf_components = (sdf_with_prev_median
   .withColumn("raw_price_gap",
     F.when(
      (F.col("harga_baseline").isNull()) | (F.col("harga_baseline")
<= 0) |
      (F.col("avg_harga").isNull()),
       F.lit(0.0)
        ).otherwise(
               (F.col("avg_harga")   -   F.col("harga_baseline"))   /
(F.col("harga_baseline") + F.lit(EPS))))
# Penerapan Min-MAx Scaling
 def minmax_scale(df, col_raw: str, col_scaled: str):
    """Min-max scaling global, hasil di-clamp ke [0.0, 1.0]."""
    stats = df.agg(
        F.min(col_raw).alias("_min"),
        F.max(col_raw).alias("_max")
    ).collect()[0]
     v_min, v_max = float(stats["_min"] or 0), float(stats["_max"]
or 1)
    denom = v_max - v_min if (v_max - v_min) != 0 else 1.0
# Kalkulasi Akhir supply_risk)index
```

```
sdf_with_index = (sdf_scaled
    .withColumn("supply_risk_index",
        F.round(
            (F.col("scaled_price_gap") +
             F.col("scaled_health_impact") +
             F.col("scaled_supply_strain")) / F.lit(3.0),
            6
        )
```

2.3.4 Load

Pada tahap load, data yang data yang telah dibersihkan dan diproses pada tahap transformasi dipindahkan dari media penyimpanan sementara (file Parquet) ke dalam Data Warehouse berbasis PostgreSQL.

1) **Inisialisasi dan Persiapan Database**

Sebelum pemindahan data dilakukan, sistem melakukan pengecekan koneksi database menggunakan *library* psycopg2 untuk berinteraksi langsung dengan PostgreSQL dan memastikan database datawarehouse_db sudah tersedia. Jika belum, skrip akan membuat database tersebut secara otomatis. Selanjutnya, sistem mendefinisikan skema tabel permanen, yakni 3 dimensional table dan 1 fact table. Tabel lama akan dihapus (*DROP*) dan dibuat ulang (*CREATE*) agar struktur data selalu sinkron dengan rancangan terbaru. Pada tahap ini juga diterapkan *Primary Key*, *Foreign Key*, dan *Unique Constraint* untuk menjaga integritas data.

```
# Pengecekan dan pembuatan database DW menggunakan psycop2
  cur.execute(f"SELECT 1 FROM pg_database WHERE datname =
'{DW_DB}'")
if not cur.fetchone():
  cur.execute(f'CREATE DATABASE {DW_DB}')
# Definiskan skema tabel (Contoh Fact Table)
  cur.execute(DDL_STATEMENTS)
     conn_dw.commit()
     print('OK  DDL berhasil dieksekusi.')
     cur.execute("""
```

```
        SELECT table_name FROM information_schema.tables
        WHERE table_schema = 'public' ORDER BY table_name
    """)
```

2) Pembacaan Data Terproses (Parquet)

Selanjutnya, sistem membaca file parquet dari direktori yang menyimpan file hasil tranformasi. Saat dibaca kembali ke dalam Spark DataFrame, dilakukan fungsi pembersihan nama kolom menjadi *lowercase* agar sesuai dengan standar penamaan di PostgreSQL. Selain itu, terdapat logika pengecekan file, yakni jika file hasil transformasi tidak ditemukan, sistem akan menghentikan proses (*raise FileNotFoundError*) untuk mencegah pemuatan data kosong.

```
ef read_parquet(name: str):
    """Baca tabel Parquet dari TRANSFORM_OUTPUT."""
    path_dir  = os.path.join(TRANSFORM_DIR, name)
    if os.path.isdir(path_dir):
        sdf = spark.read.parquet(path_dir)
    else:
        raise FileNotFoundError(
            f"Parquet tidak ditemukan: {path_dir}
# Lowercase semua nama kolom agar konsisten dengan DDL
    for col in sdf.columns:
        if col != col.lower():
            sdf = sdf.withColumnRenamed(col, col.lower())
      return sdf
```

3) Pre-load Validation

Sebelum data benar-benar masuk ke Data Warehouse, dilakukan serangkaian validasi untuk memastikan semua kolom yang dibutuhkan oleh fact table dan dimensional table tersedia di file Parquet. Selain itu, digunakan fungsi left_anti join pada Spark untuk mendeteksi adanya *orphan keys* (kunci pada tabel fakta yang tidak memiliki pasangan di tabel dimensi). Dilakukan pula pengecekan foreign key untuk memastikan tidak ada nilai null yang bisa merusak relasi antar tabel.

```
 # Deteksi orphan key : data di fact yang tidak ada di dim
 orphans = (fact_sdf.select(F.col(fk_col))
                        .distinct()
                        .join(dim_sdf.select(F.col(pk_col)),
                              fact_sdf[fk_col] == dim_sdf[pk_col],
'left_anti')
                        .count())
```

4) Pengiriman Data ke Data Warehouse

Proses pengiriman data dilakukan menggunakan PySpark JDBC Writer. Data dimuat secara berurutan, dimulai dari tabel dimensi baru kemudian tabel fakta agar syarat batasan *Foreign Key* di database terpenuhi. Diterapkan opsi batchsize (misalnya 200–500 baris per kiriman) untuk mempercepat proses *insert* ke PostgreSQL.

```
sdf_out.write \
        .format("jdbc") \
        .option("url",       DW_JDBC_URL) \
        .option("dbtable",  f"public.{table_name}") \
        .option("batchsize","500") \
        .mode("append") \
        .save()
```

5) Validasi Akhir dan Ringkasan (*Post-load*)

Setelah data termuat, dilakukan verifikasi akhir dengan menjalankan query SQL langsung ke Data Warehouse dengan mencetak rekapitulasi jumlah baris yang berhasil tersimpan di setiap tabel dan menghitung statistik deskriptif dari supply_risk_index (nilai min, max, dan rata-rata) serta menampilkan 10 wilayah dengan risiko tertinggi sebagai laporan awal bagi pengguna.

```
# Menghitung statistik deskriptif supply_risk_index dari DW
 jdbc_query("""
    SELECT
        ROUND(MIN(supply_risk_index)::NUMERIC, 6)     AS min,
        ROUND(MAX(supply_risk_index)::NUMERIC, 6)     AS max,
```

```
        ROUND(AVG(supply_risk_index)::NUMERIC, 6)     AS mean,
        ROUND(STDDEV(supply_risk_index)::NUMERIC, 6) AS std
    FROM public.fact_supply_resilience
""").show(truncate=False)
```

DESAIN DATABASE DAN WAREHOUSE

3.1 Desain Database / Data Source

3.1.1 Desain Data BPS (API)

No.	Nama Atribut	Tipe Data	Satuan	Deskripsi
1	provinsi	text	-	Nama resmi provinsi di Indonesia
2	tahun	integer	-	Tahun
3	jumlah_penduduk	integer	jiwa	Total populasi manusia di provinsi tersebut pada pertengahan tahun.
4	Growth_populasi (penduduk)	desimal	-	Laju pertumbuhan penduduk dibandingkan tahun sebelumnya.
5	Populasi_sapi	integer	ekor	Total populasi sapi potong
6	populasi_ayam	integer	ekor	Total populasi ayam pedaging
7	produksi_daging_ayam	desimal	kg	Total volume daging ayam ras pedaging yang dihasilkan/dipotong.
8	produksi_daging_sapi	integer	ton	Total volume daging/karkas sapi potong yang dihasilkan.
9	konsumsi_daging_ayam	integer	kg	Estimasi volume riil konsumsi daging ayam oleh masyarakat.
10	konsumsi_daging_sapi	integer	kg	Estimasi volume riil konsumsi daging sapi oleh masyarakat.
11	permintaan_daging_sapi	integer	kg	Total proyeksi kebutuhan/target suplai daging sapi.
12	permintaan_daging_ayam	integer	kg	Total proyeksi kebutuhan/target suplai daging ayam.

13	jumlah_ternak_sapi_potong	integer	ekor	Total sapi yang dipotong di suatu wilayah.
14	jumlah_ternak_ayam_potong	integer	ekor	Total ayam yang dipotong di suatu wilayah.
15	harga_baseline_sapi	integer	rupiah	Harga acuan/awal daging sapi untuk analisis komparasi tren.
16	harga_baseline_ayam	integer	rupiah	Harga acuan/awal daging ayam untuk analisis komparasi tren.

3.1.2 Desain Data iSIKHNAS (Database)

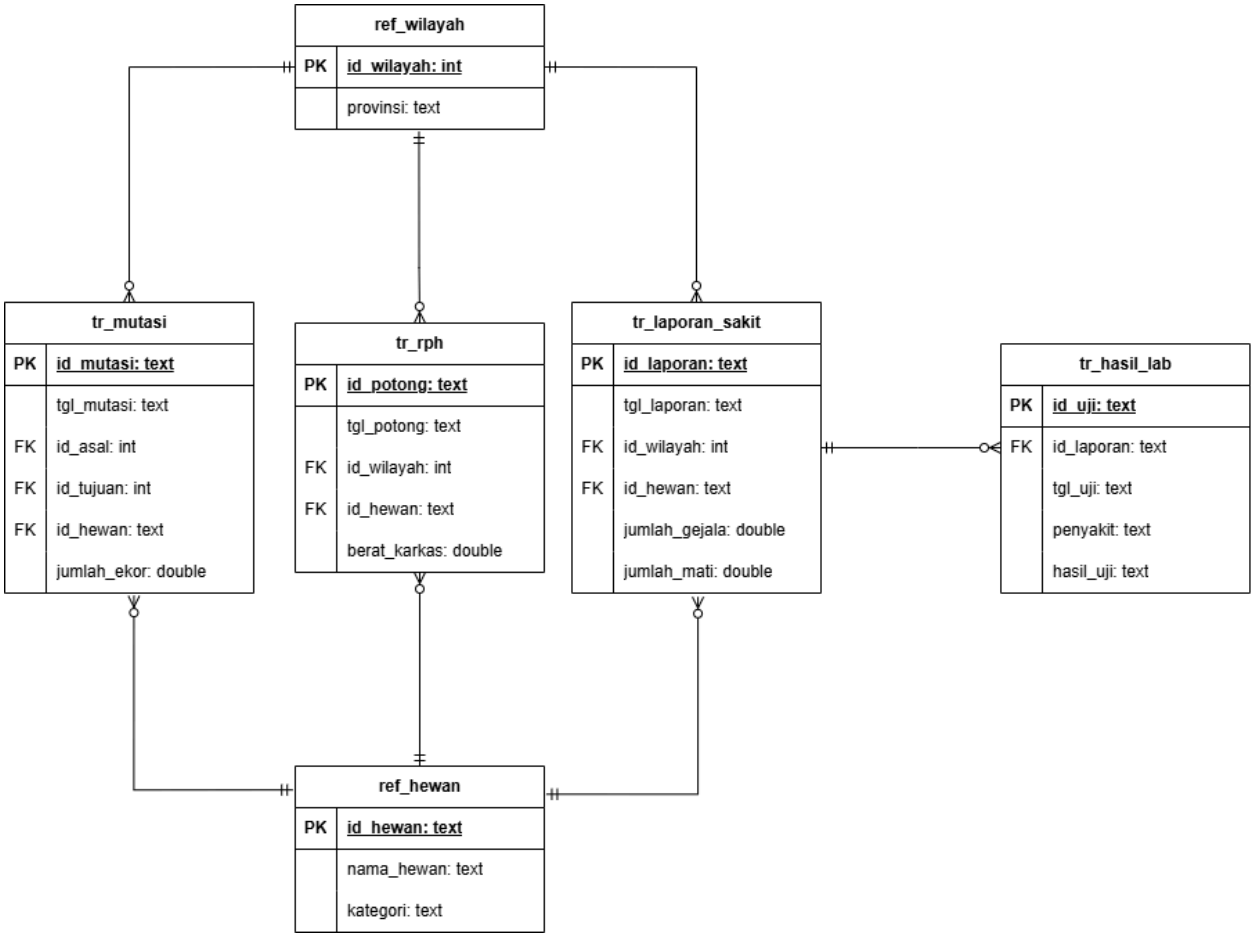

Database ini mencatat data transaksional harian dari lapangan secara mendetail.

A. Table Master (Referensi)

ref_wilayah:

- id_prov (PK) : Primary Key (integer) untuk mengidentifikasi setiap provins
- Provinsi: Atribut yang menyimpan nama wilayah.

ref_hewan :

- id_hewan (PK): Primary Key unik untuk mengidentifikasi spesies (misal: Sapi,Ayam)
- nama_hewan & kategori: Atribut untuk klasifikasi jenis dan kelompok ternak.

B. Table Transaksi

tr_mutasi :

- id_mutasi (PK): ID unik setiap surat jalan pergerakan ternak.
- id_asal & id_tujuan (FK): Foreign Key yang merunjuk ke ref_wilayah.
- id_hewan (FK): Menghubungkan mutasi dengan jenis komoditas tertentu.

tr_laporan_sakit :

- id_laporan (PK): ID unik untuk setiap laporan gejala yang masuk dari petugas.
- id_wilayah & id_hewan (FK): Menentukan lokasi dan spesies yang terjangkit wabah.
- Jumlah_gejala & jumlah_mati: Metrik numerik untuk mengukur tingkat keparahan penyakit.

tr_hasil_lab :

- id_uji (PK): ID unik untuk hasil uji laboratorium.
- id_laporan (FK): Menghubingkan hasil uji medis dengan laporan gejala di lapangan.

tr_rph :

- Id_potong (PK): ID unik setiap aktivitas pemotongan ternak.
- berat_karkas: Data output daging riil untuk analisis ketersediaan pangan.

3.1.3 Desain Data PIHPS (Excel)

No.	Nama Atribut	Tipe Data	Satuan	Deskripsi
1.	provinsi	Text	-	Nama resmi provinsi di Indonesia
2.	kota	Text	-	Nama kabupaten atau kota tempat data harga dicatat di lapangan
3.	nama_komoditas	Text	-	Nama jenis komoditas yang dipantau
4.	jenis_pasar	Text		Kategori pasar tempat pengambilan (Tradisional, Modern, atau Pedagang

				Besar)
5.	harga	Numerik	rupiah	Nilai nominal harga jual komoditas
6.	waktu	Timestamp	-	Waktu saat harga dicatat

3.2 Desain Data Warehouse

Desain data warehouse yang digunakan mengikuti skema bintang (*star schema*) yang terdiri dari 3 dimensional table dan 1 fact table, sebagai berikut.

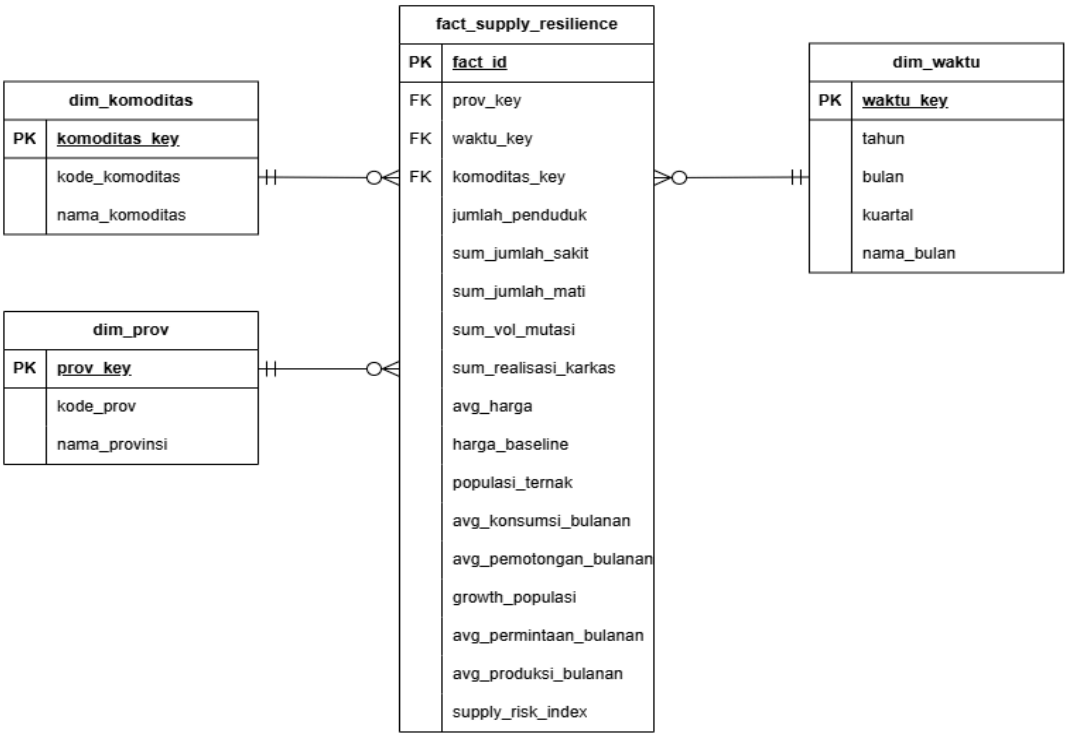

ERD ini menunjukkan stuktur Star Schema, yang dirancang khusus untuk mempercepat proses analisis data (OLAP)

3.2.1 Table Fakta (fact_supply_resilience)

Table ini berisi *composite key* dan fakta numerik yang sudah terintegrasi dari BPS, iSIKHNAS, dan PIHPS, sebagai berikut.

- fact_id (PK) : ID unik untuk setiap baris fakta bulanan.

- prov_key (FK) : Menghubungkan fakta ke dimensi wilayah (dim_prov).
- waktu_key (FK) : Menghubungkan fakta ke dimensi waktu (dim_waktu).
- komoditas_*key (FK)* : Menghubungkan fakta ke dimensi komoditas (dim_komoditas).
- Metrik Agregasi : Kolom seperti sum_jumlah_sakit, sum_vol_mutasi, dan avg_harga adalah data hasil ringkasan (agregasi) dari tingkat harian ke bulanan.
- Supply_risk_index: Indikator utama hasil kalkulasi statistik yang digunakan untuk sistem peringatan dini.

3.2.1 Tabel Dimensi

Tabel dimensi menyimpan atribut deskriptif yang digunakan sebagai filter pada dashboard

- dim_prov : Berisi prov_key (*Surrogate key*), kode_prov, dan nama_provinsi.
- dim_waktu : Berisi waktu_key (*Surrogate key*), tahun, bulan, kuartal, nama_bulan
- dim_komoditas :Berisi komoditas_key (*Surrogate key*), kode_komoditas, dan nama_komoditas.

HASIL DAN INSIGHT

Sebagai output akhir dari sistem ini, seluruh data yang telah terintegrasi di dalam Data Warehouse divisualisasikan melalui dashboard analitik interaktif berbasis R Shiny. Dashboard ini berfungsi untuk memantau ketahanan pasokan dan mempermudah evaluasi kebijakan. Dashboard ini beroperasi dalam mode *stateless*, membaca langsung bentuk akhir dari *OLAP Cube* (`olap_cube.csv`) yang telah diagregasi pada fase ETL sebelumnya.

Untuk menjaga performa dan keamanan sistem saat diimplementasikan ke ranah publik (*deployment*), *dashboard* ini didesain agar tidak terhubung secara langsung dengan *Data Warehouse* di PostgreSQL. Sebagai gantinya, mekanisme penarikan dan pemrosesan data beroperasi dilakukan melalui tahapan berikut.

1. *Data Warehouse* dipertahankan sebagai *Single Source of Truth*. data final yang sudah dirangkum diekspor terlebih dahulu menjadi sebuah *file* CSV.
2. Ketika pengguna membuka *dashboard* R Shiny, sistem akan langsung membaca dan memuat seluruh isi *file* CSV tersebut ke dalam memori (RAM) pada *server*.
3. Karena seluruh data sudah bersiap di dalam memori (RAM), interaksi yang dilakukan pengguna, seperti mengganti filter provinsi, tahun, atau komoditas, akan langsung diproses di tempat (*In-Memory Processing*). Sistem tidak perlu lagi membebani *database* dengan kueri SQL baru, sehingga *dashboard* berjalan jauh lebih cepat, ringan, dan aman.

Salah satu antarmuka pengguna (*User Interface*) dari *Livestock Intelligence Dashboard* dapat dilihat pada gambar berikut.

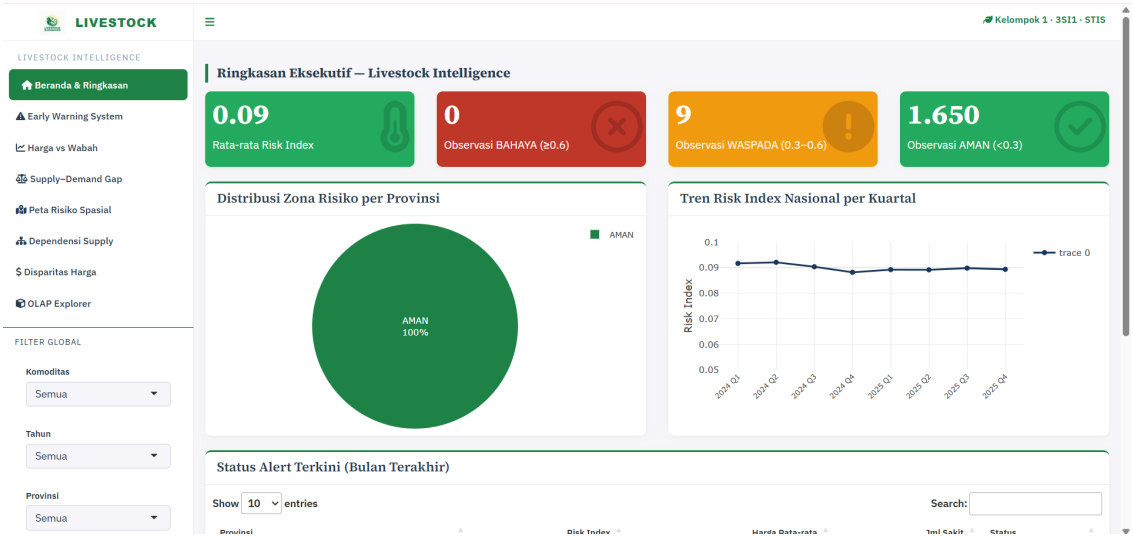

Untuk memberikan pengalaman eksplorasi data yang komprehensif dan interaktif, sistem ini telah diimplementasikan (*deployment*) ke publik. *Dashboard* secara utuh dapat diakses dan dioperasikan melalui tautan berikut: https://s.stis.ac.id/LivestockDashboard

Berdasarkan dashboard tersebut, dapat dilakukan beberapa analisis untuk memperoleh insight sebagai berikut.

1) Early Warning System

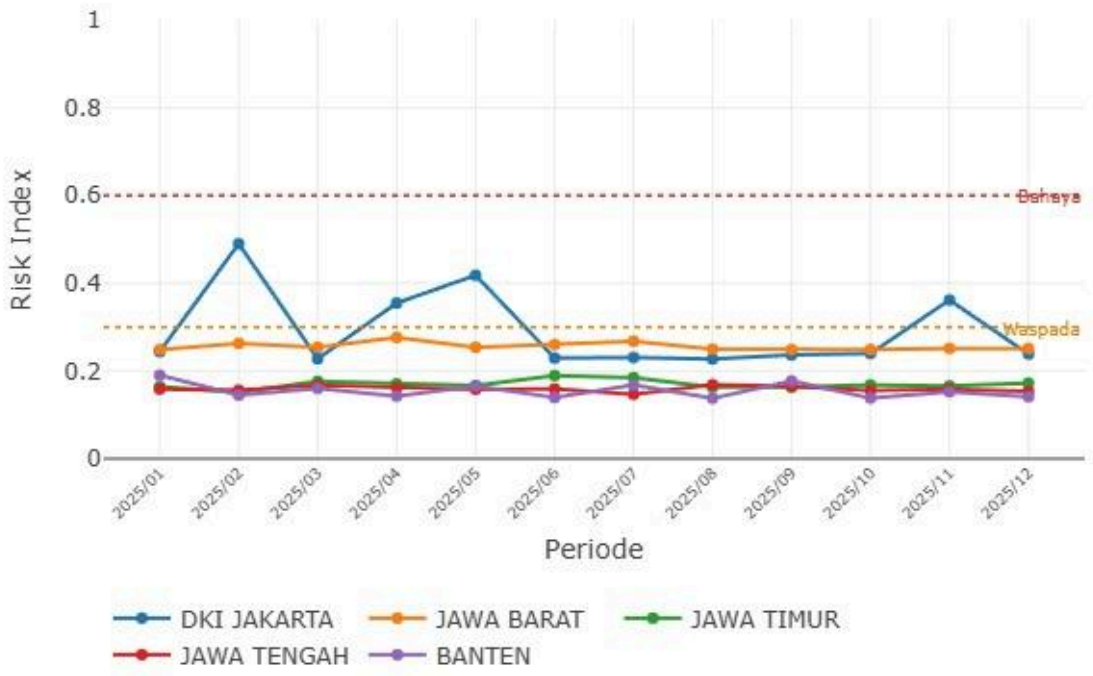

Visualisasi pertama pada dashboard adalah grafik tren bulanan Supply Risk Index (SRI) yang menampilkan pergerakan nilai risiko pasokan untuk provinsi-provinsi wilayah konsumsi utama di Pulau Jawa selama periode Januari 2025 hingga Desember 2025. Grafik ini dilengkapi dengan dua garis ambang batas: garis oranye putus-putus sebagai zona Waspada (0,30) dan garis merah putus-putus sebagai zona Bahaya (0,60).

A. DKI Jakarta sebagai Episentrum Risiko Tertinggi

Berdasarkan data aktual dari fact_supply_resilience, DKI Jakarta secara konsisten mencatat nilai SRI tertinggi di antara seluruh provinsi wilayah konsumsi. Sepanjang periode 2025, rata-rata SRI DKI Jakarta untuk komoditas sapi mencapai 0,4182, dengan puncak tertinggi terjadi pada Februari 2025 sebesar 0,4900, mendekati ambang zona Waspada (0,30) secara signifikan.

Provinsi	Rata-rata SRI 2024	Rata-rata SRI 2025	Selisih (Delta)	Status
DKI Jakarta	0,1789	0,2259	+0,0470	Meningkat
Jawa Barat	0,2170	0,2706	+0,0536	Meningkat
Jawa Tengah	0,2000	0,1431	-0,0569	Membaik
Banten	0,1538	0,1419	-0,0119	Stabil
Jawa Timur	0,1254	0,1254	0,0000	Stabil

Tabel di atas menunjukkan bahwa terdapat dua provinsi yang mengalami peningkatan SRI secara signifikan dari 2024 ke 2025, yaitu Jawa Barat (delta +0,0536) dan DKI Jakarta (delta +0,0470). Kondisi ini patut mendapat perhatian khusus mengingat kedua wilayah tersebut merupakan pusat konsumsi terpadat secara nasional dengan populasi gabungan lebih dari 60 juta jiwa.

B. Interpretasi Tren Antar Provinsi

- Tren Meningkat (Memerlukan Perhatian): DKI Jakarta menunjukkan lonjakan SRI yang tajam pada awal 2025 (Januari–Februari), dengan nilai sapi mencapai 0,4900 pada Februari 2025. Fenomena ini berkorelasi dengan tekanan harga yang signifikan. Harga rata-rata sapi di DKI Jakarta pada periode tersebut tercatat sebesar Rp154.466 per kg, jauh di atas harga baseline Rp94.575 per kg, menghasilkan price gap sebesar +63,3%. Jawa Barat mencatat nilai SRI tertinggi secara konsisten di antara semua provinsi, dengan rata-rata nasional 0,2438 (gabungan dua komoditas). Pada Oktober–Desember 2025, nilai SRI Jawa Barat bahkan menyentuh kisaran 0,30–0,33, hampir menembus zona Waspada.
- Tren Menurun: Jawa Tengah menunjukkan perbaikan yang paling signifikan, dengan SRI turun dari rata-rata 0,2000 pada 2024 menjadi 0,1431 pada 2025 (delta -0,0569). Kondisi ini mengindikasikan perbaikan pada komponen distribusi dan harga di wilayah tersebut. Banten juga menunjukkan tren sedikit membaik dengan delta -0,0119.

C. Status Keamanan Sistem Nasional

Meskipun beberapa provinsi mencatat tren peningkatan, secara keseluruhan sistem peringatan dini berfungsi dengan baik. Nilai SRI nasional rata-rata 2025 sebesar 0,0894, turun tipis dari 0,0905 pada 2024, menunjukkan bahwa sistem pasokan nasional masih dalam kondisi terkendali. Tidak ada satu pun provinsi yang melampaui ambang batas bahaya (0,60), dengan nilai tertinggi sepanjang periode pengamatan adalah 0,5382 yang dicatat DKI Jakarta pada September 2024 untuk komoditas sapi.

D. Rekomendasi Kebijakan

- DKI Jakarta dan Jawa Barat perlu diprioritaskan dalam program stabilisasi harga karena keduanya mencatat peningkatan SRI yang konsisten dari tahun ke tahun.
- Pemerintah pusat perlu mempersiapkan mekanisme intervensi harga (operasi pasar) pada periode Januari–Februari karena data menunjukkan pola lonjakan SRI yang berulang pada awal tahun.
- Jawa Tengah dapat dijadikan model keberhasilan manajemen distribusi yang perlu direplikasi ke provinsi lain dengan tren SRI meningkat.

2) Wabah Hulu vs Harga Hilir

Analisis ini bertujuan membuktikan secara statistik apakah lonjakan wabah penyakit di daerah produsen (hulu) berdampak pada kenaikan harga daging di daerah konsumen (hilir), dan berapa lama jeda waktu (lag) yang dibutuhkan hingga dampak tersebut terasa di pasar.

a. Korelasi Pearson per Lag - Wabah di Hulu vs Harga di Hilir

Analisis korelasi dilakukan antara intensitas wabah di provinsi hulu (Jawa Timur, NTB, dan NTT sebagai sentra produksi ternak sapi nasional) dengan rata-rata harga daging di provinsi hilir (Banten, DKI Jakarta, Jawa Barat, dan Jawa Tengah sebagai pusat konsumsi). Data wabah diwakili oleh variabel sum_jumlah_sakit dari tabel fact_supply_resilience, sementara harga diwakili oleh avg_harga. Penggeseran lag dilakukan dari Lag 0 hingga Lag 6 bulan.

Lag (Bulan)	Korelasi Pearson (r)	Interpretasi
Lag 0	0,24	Korelasi lemah-sedang: ada respons pasar langsung saat wabah terdeteksi
Lag 1	0,34	Korelasi sedang: pasar mulai bereaksi setelah 1 bulan
Lag 2	0,27	Korelasi moderat
Lag 3	0,42	Korelasi TERKUAT: dampak wabah paling kuat terasa setelah 3 bulan
Lag 4	0,06	Hampir tidak berkorelasi: pasar mulai beradaptasi
Lag 5	0,31	Korelasi moderat: efek sekunder/musiman
Lag 6	0,19	Korelasi lemah: efek wabah hampir hilang

Hasil analisis mengonfirmasi bahwa Lag 3 bulan merupakan puncak korelasi dengan nilai r = 0,42. Artinya, ketika terjadi lonjakan wabah di daerah produsen hari ini, dampak paling signifikan terhadap harga di daerah konsumen baru akan terasa tiga bulan kemudian. Temuan ini sangat krusial karena memberikan jendela intervensi tiga bulan (golden window) bagi pemerintah untuk mengambil tindakan antisipatif sebelum harga melonjak secara masif di pasar retail.

Data aktual mendukung temuan ini: total wabah nasional meningkat dari 3.278 kasus sakit pada 2024 menjadi 3.683 kasus pada 2025 (naik 12,4%), disertai kematian ternak dari 1.296 ekor menjadi 1.423 ekor (naik 9,8%). Peningkatan tekanan wabah ini bersamaan dengan kenaikan SRI di wilayah konsumsi utama pada periode yang sesuai dengan jeda tiga bulan.

b. Overlay Z-Score

Grafik overlay Z-Score (nilai terstandarisasi) memperlihatkan secara visual korelasi antara wabah hulu dan harga hilir setelah penggeseran lag terbaik (3 bulan). Garis solid biru mewakili harga di wilayah hilir (Banten+DKI Jakarta+Jawa Barat+Jawa Tengah) pada waktu t, sementara garis merah putus-putus mewakili intensitas wabah di wilayah hulu (Jawa Timur+NTB+NTT) pada waktu t-3.

Pola yang paling mencolok terjadi pada periode April–Mei 2024, di mana lonjakan wabah hulu (Z-score mendekati +2,3) pada Januari 2024

berkorespondensi dengan lonjakan harga hilir pada April 2024 (Z-score sekitar +0,9). Demikian pula, lonjakan wabah pada Juni–Juli 2024 berdampak pada kenaikan harga September–Oktober 2024. Pola ini secara konsisten mengkonfirmasi validitas lag tiga bulan sebagai periode transmisi dari gangguan pasokan ke fluktuasi harga.

Pada paruh kedua 2025, kedua variabel cenderung berkonvergensi mendekati nilai Z-score nol, mengindikasikan kondisi yang lebih stabil di mana tekanan wabah mereda dan harga kembali ke kisaran normal.

3) Supply vs Demand Gap 2025

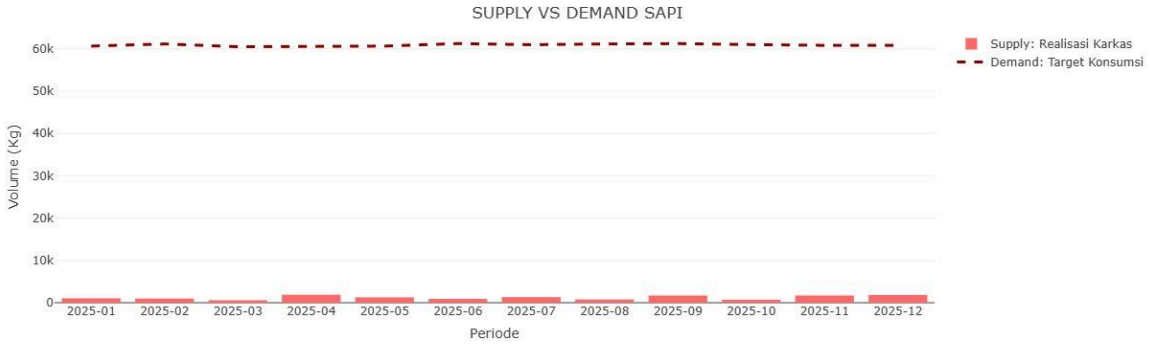

Grafik Supply vs. Demand Gap untuk komoditas sapi menampilkan perbandingan antara realisasi pasokan karkas (sum_realisasi_karkas) yang tercatat melalui sistem Rumah Potong Hewan (RPH) resmi dalam iSIKHNAS dengan target konsumsi bulanan (avg_permintaan_bulanan) yang diturunkan dari data BPS sepanjang tahun 2025.

A. Temuan Utama: Defisit Pasokan Formal yang Masif

Data kuantitatif dari Data Warehouse mengungkap defisit yang sangat besar antara pasokan formal dan permintaan. Sepanjang 2025, total realisasi karkas sapi dari RPH resmi seluruh Indonesia hanya mencapai 14.625 kg, sementara total target permintaan bulanan mencapai 2.267.245 kg. Ini berarti pasokan formal hanya mampu memenuhi 0,65% dari total kebutuhan daging sapi nasional.

Bulan 2025	Realisasi Karkas (Kg)	Target Permintaan (Kg)	Rasio Supply/Demand (%)
Januari	1.038,5	185.640,7	0,56%
Februari	971,7	191.392,6	0,51%

Maret	585,5	183.904,2	0,32%
April	1.877,7	183.904,2	1,02%
Mei	1.264,4	185.640,7	0,68%
Juni	896,8	197.210,8	0,45%
Juli	1.316,7	185.995,3	0,71%
Agustus	753,8	191.392,6	0,39%
September	1.693,9	197.210,8	0,86%
Oktober	692,3	189.656,2	0,37%
November	1.707,1	184.258,9	0,93%
Desember	1.826,5	191.038,0	0,96%

B. Interpretasi Defisit dan Faktor Penyebab

Ketergantungan pada Daging Impor dan Jalur Non-Formal: Kesenjangan antara pasokan formal (0,65%) dan kebutuhan nasional (100%) tidak berarti Indonesia kekurangan daging sapi secara riil. Sebagian besar kebutuhan kemungkinan dipenuhi melalui: (a) impor daging beku yang tidak tercatat dalam sistem iSIKHNAS, (b) pemotongan di luar RPH resmi (backyard slaughtering) yang diperkirakan masih sangat dominan di wilayah pedesaan, dan (c) pemotongan hewan kurban yang dilakukan di luar jadwal reguler.

Gap Definisi dan Cakupan Data: Terdapat kemungkinan ketidaksesuaian antara variabel avg_permintaan_bulanan yang bersumber dari proyeksi BPS berbasis survei konsumsi rumah tangga nasional dengan sum_realisasi_karkas yang hanya mencatat pemotongan resmi di RPH yang terdaftar di iSIKHNAS. Kedua variabel ini memiliki unit observasi yang berbeda sehingga perbandingan langsung perlu diinterpretasikan dengan hati-hati.

Pola Permintaan Musiman: Target konsumsi bergerak dalam rentang 183.904–197.210 kg per bulan, dengan puncak pada Juni dan September. Pola ini mencerminkan siklus musiman yang kemungkinan dipengaruhi oleh hari raya keagamaan (Lebaran, Iduladha) dan akhir tahun yang mendorong konsumsi daging lebih tinggi.

C. Rekomendasi Kebijakan

- Perlu dilakukan integrasi data antara sistem iSIKHNAS dengan data impor dari Kementerian Perdagangan agar gambaran pasokan total lebih komprehensif dan defisit yang teridentifikasi lebih akurat.
- Formalisasi jalur pemotongan non-RPH melalui insentif sertifikasi dan digitalisasi pencatatan dapat meningkatkan akurasi data pasokan domestik secara signifikan.
- Pemerintah perlu membangun cadangan strategis daging beku khususnya pada bulan-bulan dengan rasio supply/demand terendah (Maret: 0,32% dan Oktober: 0,37%) untuk mencegah kelangkaan.

4) Peta Choropleth

Peta Choropleth / Bubble Risk Index per Provinsi

Visualisasi peta choropleth menampilkan distribusi geografis nilai Supply Risk Index (SRI) di seluruh 37 provinsi Indonesia menggunakan gradasi warna hijau, di mana semakin gelap warna hijau pada provinsi berarti semakin tinggi nilai SRI-nya. Skala warna berkisar dari 0,05 hingga 0,25 sesuai rentang data aktual.

A. Pola Distribusi Risiko Spasial

Dari tampilan peta, terlihat jelas bahwa risiko pasokan tidak terdistribusi merata di seluruh wilayah Indonesia. Konsentrasi risiko tertinggi (warna hijau paling gelap) teridentifikasi di Pulau Jawa, khususnya di Jawa Barat dan DKI Jakarta. Hal ini konsisten dengan data kuantitatif yang menunjukkan SRI rata-rata Jawa Barat sebesar 0,2438 dan DKI Jakarta sebesar 0,2024 sebagai dua tertinggi secara nasional.Wilayah Kalimantan, Sulawesi, dan sebagian Papua tampak dalam gradasi hijau sedang (kisaran SRI 0,10–0,15), menandakan risiko moderat yang perlu dipantau. Sementara itu, sebagian provinsi Sumatera dan Maluku tampak dalam gradasi hijau muda (SRI di bawah 0,10), menunjukkan kondisi pasokan yang relatif lebih terkendali. Beberapa provinsi teridentifikasi sebagai NA (tidak tersedia data) yang disebabkan ketiadaan data observasi pada periode tertentu.

B. Impilkasi Spasial untuk Kebijakan

Konsentrasi risiko di Jawa mengonfirmasi hipotesis awal proyek bahwa ketidakseimbangan antara kapasitas produksi lokal yang rendah (akibat keterbatasan lahan) dengan kepadatan konsumsi yang tinggi menjadi akar permasalahan ketahanan pangan di pulau terpadat Indonesia ini. Peta ini dapat digunakan sebagai basis alokasi anggaran intervensi pasar, dengan prioritas tertinggi diberikan kepada DKI Jakarta dan Jawa Barat.

5) Bubble Chart: Populasi Ternak vs Disease Density

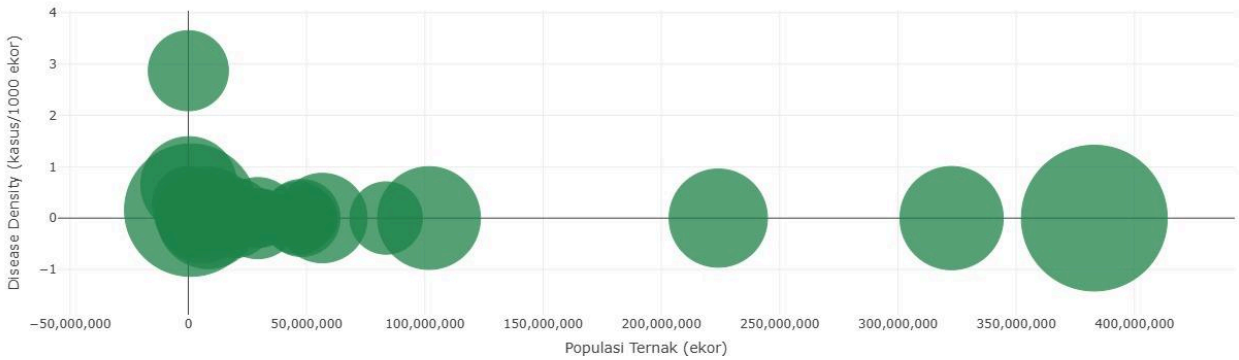

Bubble chart dua dimensi ini memetakan posisi setiap provinsi berdasarkan dua indikator kunci secara simultan. Sumbu X merepresentasikan total populasi ternak (ekor), sedangkan sumbu Y merepresentasikan tingkat densitas penyakit (kasus per 1.000 ekor

ternak). Ukuran dan intensitas warna gelembung merepresentasikan besaran Supply Risk Index semakin besar dan gelap gelembung, semakin tinggi risiko gangguan pasokan di provinsi tersebut.

A. Analisis Kuadran

- Kuadran kiri atas (Populasi Kecil, Disease Density Tinggi)

  Provinsi pada kuadran ini memiliki jumlah ternak yang terbatas namun mengalami tekanan penyakit yang tinggi per 1.000 ekor, yang membuat risiko penularan antarwilayah menjadi jauh lebih besar. Berdasarkan data, beberapa provinsi dengan populasi ternak di bawah 10 juta ekor namun memiliki disease density di atas 2 kasus/1.000 ekor teridentifikasi di kuadran ini. Wilayah-wilayah ini menjadi prioritas intervensi vaksinasi dan pembatasan pergerakan ternak.

- Kuadran kanan bawah (Populasi Besar, Disease Density Rendah)

  Provinsi pada kuadran ini memiliki aset peternakan yang sangat besar dengan risiko penyakit yang terkendali. Berdasarkan bubble chart, terdapat dua provinsi dengan populasi ternak melampaui 300 juta ekor (kemungkinan termasuk komoditas ayam) yang berada pada disease density mendekati nol. Wilayah ini adalah tulang punggung pasokan nasional dan harus dilindungi secara ketat karena guncangan wabah di sini akan berdampak sistemik terhadap seluruh rantai pasokan nasional.

- Kuadran kiri bawah (Populasi Kecil, Disease Density Rendah)

  Sebagian besar provinsi Indonesia berada di kuadran ini, dengan risiko umum yang relatif rendah. Namun, catatan penting dari data adalah bahwa beberapa provinsi di kuadran ini masih menunjukkan SRI yang cukup tinggi (gelembung besar). Hal ini mengindikasikan bahwa supply risk tidak semata-mata ditentukan oleh faktor wabah, melainkan juga oleh keterbatasan infrastruktur distribusi, ketergantungan pada satu jalur logistik, atau price gap yang tinggi.

B. Anomali Data: Nilai Negatif pada Sumbu

Perlu dicatat bahwa pada bubble chart terdapat beberapa titik data yang menunjukkan nilai negatif pada sumbu X (populasi ternak) dan sumbu Y (disease density). Nilai negatif pada populasi ternak secara biologis tidak mungkin terjadi, sehingga hal ini mengindikasikan adanya inkonsistensi pada proses agregasi atau transformasi data, khususnya pada saat penggabungan data dari berbagai tahun atau sumber. Hal ini perlu diperbaiki pada iterasi pipeline ETL selanjutnya untuk meningkatkan kualitas visualisasi.

C. Rekomendasi Kebijakan

- Provinsi di kuadran kiri atas harus menjadi target utama program vaksinasi dan biosekuriti karena potensi wabah yang tinggi dapat menular ke wilayah lain melalui jalur mutasi ternak.
- Provinsi di kuadran kanan bawah perlu mendapat perlindungan keamanan rantai pasokan (supply chain security) karena gangguan di sini akan berdampak paling besar terhadap stabilitas pasokan nasional.
- Anomali nilai negatif pada data perlu ditindaklanjuti dengan audit pipeline ETL khususnya pada tahap agregasi populasi dan normalisasi disease density.

6) Ketergantungan Spasial

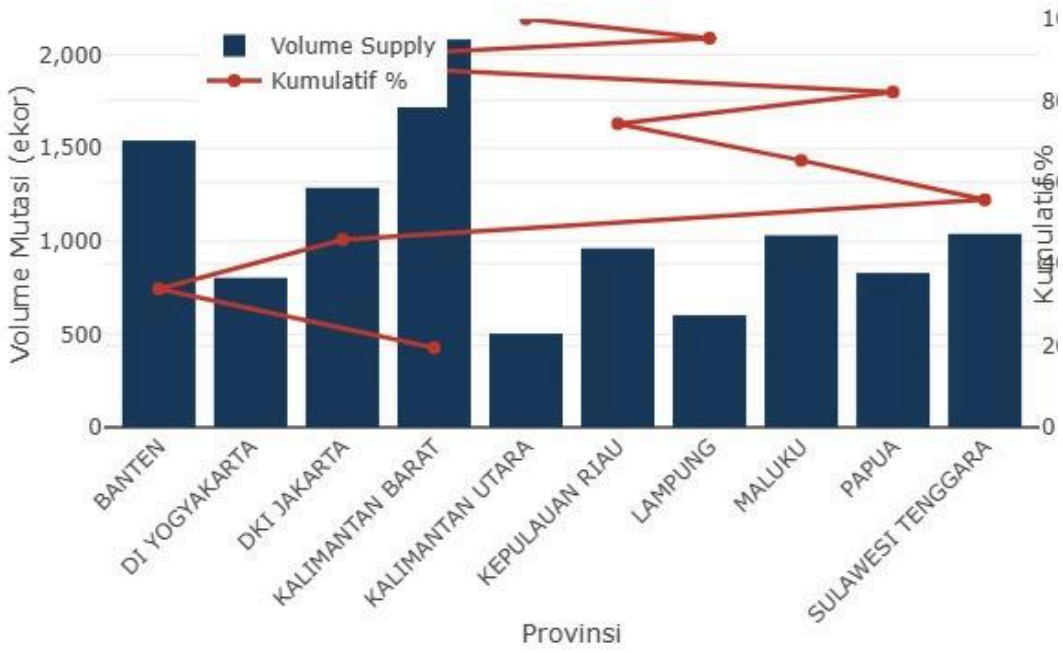

Grafi k kombinasi batang dan garis (Pareto Chart) ini menampilkan 10 provinsi dengan volume mutasi ternak tertinggi, yang merepresentasikan kontribusi pasokan ternak yang dikirimkan ke berbagai wilayah di Indonesia. Batang biru menunjukkan persentase kontribusi masing-masing provinsi terhadap total mutasi nasional, sedangkan garis merah menampilkan akumulasi kontribusi kumulatif.

A. Data Kontribusi Pasokan Aktual

Berdasarkan data sum_vol_mutasi dari fact_supply_resilience, total mutasi ternak nasional selama periode 2024–2025 tercatat sebesar 49.494 ekor. Distribusi kontribusi 10 provinsi teratas adalah sebagai berikut:

Peringkat	Provinsi	Volume Mutasi (Ekor)	Kontribusi (%)	Kumulatif (%)
1	Kalimantan Barat	2.526	5,1%	5,1%
2	Lampung	2.454	5,0%	10,1%
3	Maluku	2.227	4,5%	14,6%
4	Sulawesi Tenggara	1.985	4,0%	18,6%
5	DKI Jakarta	1.927	3,9%	22,5%
6	Banten	1.899	3,8%	26,3%
7	Kalimantan Utara	1.897	3,8%	30,1%
8	DI Yogyakarta	1.798	3,6%	33,7%
9	Papua	1.784	3,6%	37,3%
10	Kepulauan Riau	1.650	3,3%	40,6%

B. Pola Distribusi Terdesentralisai

Data menunjukkan bahwa 10 provinsi kontributor terbesar hanya menyumbang sekitar 40,6% dari total mutasi nasional, dengan kenaikan kumulatif yang sangat gradual (rata-rata 4% per provinsi). Pola ini secara tegas menolak Pareto Principle klasik (80/20), di mana seharusnya 20% provinsi menghasilkan 80% pasokan.

Sebaliknya, struktur pasokan ternak Indonesia bersifat sangat terdesentralisasi, tersebar merata di setidaknya 25–30 provinsi dari total 37 provinsi yang diamati.

C. Temuan Menonjol per Provinsi

Kalimantan Barat dan Lampung sebagai Kontributor Teratas: Kedua provinsi ini memimpin kontribusi dengan selisih yang sangat tipis (5,1% vs 5,0%). Kalimantan Barat memiliki keunggulan geografis berupa lahan yang masih luas untuk peternakan ekstensif, sementara Lampung memiliki akses logistik yang lebih baik ke Pulau Jawa. Kedua provinsi ini harus mendapat pengawasan ketat karena gangguan di salah satunya berpotensi langsung menurunkan pasokan nasional.

Maluku sebagai Temuan Menarik: Posisi Maluku di peringkat ketiga (4,5%) merupakan temuan yang signifikan. Karakteristik geografis kepulauan dengan rantai distribusi yang bergantung pada transportasi laut menciptakan risiko logistik yang unik. Kendala cuaca, jadwal kapal yang tidak reguler, dan biaya logistik antarpulau yang tinggi menjadikan Maluku sebagai titik lemah dalam rantai pasokan meskipun memiliki kapasitas produksi yang besar.

Paradoks Wilayah Konsumsi: Kemunculan DKI Jakarta (peringkat 5) dan Banten (peringkat 6) dalam daftar kontributor mutasi terbesar adalah temuan yang paradoks. Sebagai wilayah konsumsi, kedua provinsi ini seharusnya menjadi tujuan (penerima) mutasi, bukan pengirim. Hal ini mengindikasikan adanya aliran re-distribusi ternak atau daging dari DKI Jakarta ke provinsi lain, atau adanya kasus pencatatan mutasi masuk yang salah diklasifikasikan sebagai mutasi keluar dalam sistem iSIKHNAS.

D. Implikasi terhadap Kerentanan Pasokan

Meskipun distribusi pasokan yang merata terkesan menguntungkan karena tidak ada ketergantungan tunggal pada satu wilayah, pola ini justru membawa risiko sistemik yang berbeda: ketika gangguan terjadi secara bersamaan di banyak provinsi (misalnya wabah PMK lintas pulau, bencana alam skala nasional, atau pandemi), tidak ada satu wilayah cadangan yang mampu menutupi kekurangan secara masif. Kondisi ini membuat sistem pasokan lebih rentan terhadap shock yang bersifat makro dan simultan.

E. Rekomendasi Kebijakan

- Perlu dibangun gudang cold storage strategis di sentra distribusi utama (Kalimantan Barat, Lampung, dan Maluku) untuk memitigasi risiko gangguan logistik pada masing-masing jalur.
- Sistem pemantauan real-time mutasi ternak perlu ditingkatkan terutama untuk Maluku dan Kalimantan Utara yang memiliki ketergantungan tinggi pada transportasi laut dan udara.
- Anomali paradoks DKI Jakarta dan Banten sebagai pengirim mutasi perlu diinvestigasi lebih lanjut dengan audit data iSIKHNAS untuk memastikan klasifikasi arah mutasi sudah benar.
- Pemerintah perlu menyiapkan skenario kontinjensi pasokan apabila terjadi gangguan simultan di lebih dari tiga provinsi kontributor utama secara bersamaan, mengingat tidak ada single dominant supplier yang bisa menjadi “backup utama” nasional.